

ROFORMER: 采用旋转位置嵌入的增强型 Transformer 架构

Jianlin Su

追一科技有限公司 深圳
bojonesu@wezhuiyi.com

Yu Lu

追一科技有限公司 深圳
julianlu@wezhuiyi.com

Shengfeng Pan

追一科技有限公司 深圳
nickpan@wezhuiyi.com

Ahmed Murtadha

追一科技有限公司 深圳
mengjiayi@wezhuiyi.com

Bo Wen

追一科技有限公司 深圳
brucewen@wezhuiyi.com

Yunfeng Liu

追一科技有限公司 深圳
glenliu@wezhuiyi.com

2023年11月9日

摘要

位置编码近期已在 Transformer 架构中展现出有效性。它为对序列中不同位置元素之间的依赖建模提供了有价值的监督。本文首先研究了将位置信息融入基于 Transformer 的语言模型学习过程的多种方法。随后, 我们提出了一种名为 Rotary Position Embedding (RoPE) 的新方法, 以有效利用位置信息。具体而言, 所提出的 RoPE 使用旋转矩阵对绝对位置进行编码, 同时在自注意力的公式中纳入显式的相对位置依赖。值得注意的是, RoPE 具备若干有益性质, 包括序列长度的灵活性、随相对距离增大而衰减的标记间依赖, 以及为线性自注意力配备相对位置编码的能力。最后, 我们在多种长文本分类基准数据集上评估了采用旋转位置嵌入的增强型 Transformer, 也称为 RoFormer。我们的实验表明, 它始终优于其他替代方法。此外, 我们提供了理论分析来解释部分实验结果。RoFormer 已集成进 Huggingface: https://huggingface.co/docs/transformers/model_doc/roformer。

关键词 预训练 语言模型 · 位置信息编码 · 预训练 · 自然语言处理。

1 引言

词语的顺序对于自然语言理解具有重要价值。基于循环神经网络 (RRNs) 的模型通过沿时间维度递归计算隐藏状态来编码 Token 的顺序。基于卷积神经网络 (CNNs) 的模型 Gehring 等人 [2017] 通常被认为与位置无关, 但近期工作 Islam 等人 [2020] 表明, 常用的填充操作可以隐式地学习位置信息。近年来, 建立在 Transformer 架构 Vaswani 等人[2017], 之上的预训练语言模型 (PLMs) 在各类自然语言处理 (NLP) 任务上取得了当前最先进水平的性能, 其中包括上下文表示学习 Devlin 等人 [2019]、机器翻译 Vaswani 等人 [2017], 和语言建模 Radford 等人 [2019], 等。与基于 RRNs 和 CNNs 的模型不同, PLMs 利用自注意力机制从语义上捕获给定语料的上下文表示。因此, PLMs 在并行化方面相较 RNNs 有显著提升, 并且相比 CNNs¹提高了对更长距离 Token 间关系的建模能力。

¹多个 CNN 层的堆叠

也可以捕获更长的标记内部关系, 这里我们

仅考虑单层设置。

值得注意的是，当前 PLMs 的自注意力架构已被证明与位置无关 Yun 等人[2020]。基于这一观点，已有多方法被提出，将位置信息编码进学习过程。一方面，通过预定义函数生成的绝对位置编码 Vaswani 等人 [2017] 被加到上下文表示中，同时也采用可训练的绝对位置编码 Gehring 等人 [2017], Devlin 等人 [2019], Lan 等人 [2020], Clark 等人 [2020], Radford 等人 [2019], Radford 和 Narasimhan [2018]。另一方面，以往的工作 Parikh 等人 [2016], Shaw 等人 [2018], Huang 等人 [2018], Dai 等人 [2019], Yang 等人 [2019], Raffel 等人 [2020], Ke 等人 [2020], He 等人 [2020], Huang 等人 [2020] 聚焦于相对位置编码，通常将相对位置信息编码进注意机制。除上述方法外，Liu 等人 [2020] 的作者提出从 Neural ODE Chen 等人 [2018a], 的视角来建模位置编码的依赖关系，而 Wang 等人 [2020] 的作者则提出在复数空间中建模位置信息。尽管这些方法有效，它们通常是将位置信息加到上下文表示上，因此并不适用于线性自注意力架构。在本文中，我们提出了一种新方法——旋转位置嵌入（RoPE），用于将位置信息引入 PLMS 的学习过程中。具体而言，RoPE 通过旋转矩阵对绝对位置进行编码，同时在自注意力的公式中引入显式的相对位置依赖。需要指出的是，所提出的 RoPE 在多项有价值的性质上优于现有方法，包括对序列长度的灵活性、相对距离增大时标记间依赖的衰减，以及为线性自注意力配备相对位置编码的能力。在多种长文本分类基准数据集上的实验结果表明，采用旋转位置嵌入的增强型 Transformer 架构，即 RoFormer，相较于基线方法能够取得更好的性能，从而证明了所提 RoPE 的有效性。

简而言之，我们的贡献主要有三点：

- 我们调研了现有的相对位置编码方法，发现它们大多基于将位置编码加到上下文表示并进行分解的思想。我们提出了一种新方法——旋转位置嵌入（RoPE），用于将位置信息引入 PLMS 的学习过程中。其关键思想是用一个具有清晰理论解释的旋转矩阵与上下文表示相乘来编码相对位置。
- 我们研究 RoPE 的性质，并表明它随着相对距离的增加而衰减，这对于自然语言编码是理想的。我们进一步指出，先前基于相对位置编码的方法与线性自注意力不兼容，
- 我们在多种长文本基准数据集上评估了所提出的 RoFormer。我们的实验表明，与替代方案相比，它始终取得了更好的性能。部分使用预训练语言模型的实验可在 GitHub 查看：<https://github.com/ZhuiyiTechnology/roformer>。

本文其余部分组织如下。我们建立自注意力架构中位置编码问题的形式化描述，并在第(2)节回顾以往工作。随后我们在第(3)节描述旋转位置编码（RoPE）并研究其性质。我们在第(4)节报告实验。最后，我们在第(5)节对本文进行总结。

2 背景与相关工作

2.1 预备知识

令 $\mathbb{S}_N = \{w_i\}_{i=1}^N$ 为一个由 N 输入标记组成的序列，其中 w_i 是第 i^{th} 个元素。与 $\mathbb{S}_N$ 对应的词嵌入记为 $\mathbb{E}_N = \{\mathbf{x}_i\}_{i=1}^N$ ，其中 $\mathbf{x}_i \in \mathbb{R}^d$ 是标记 w_i 的 d 维词嵌入向量（不含位置信息）。自注意力首先将位置信息融入词嵌入，并将其变换为查询、键和数值表示。

$$\begin{aligned} \mathbf{q}_m &= f_q(\mathbf{x}_m, m) \\ \mathbf{k}_n &= f_k(\mathbf{x}_n, n) \\ \mathbf{v}_n &= f_v(\mathbf{x}_n, n), \end{aligned} \tag{1}$$

其中， $\mathbf{q}_m, \mathbf{k}_n$ 和 $\mathbf{v}_n$ 分别通过 f_q, f_k 和 f_v 引入 m^{th} 和 n^{th} 位置。随后使用查询和键的值来计算注意权重，而输出被计算为对数值

表示。

$$a_{m,n} = \frac{\exp(\frac{\mathbf{q}_m^\top \mathbf{k}_n}{\sqrt{d}})}{\sum_{j=1}^N \exp(\frac{\mathbf{q}_m^\top \mathbf{k}_j}{\sqrt{d}})} \quad (2)$$

$$\mathbf{o}_m = \sum_{n=1}^N a_{m,n} \mathbf{v}_n$$

基于 Transformer 架构的位置编码的现有方法主要侧重于选择一个合适的函数来构成公式 (1)。

2.2 绝对位置嵌入

对公式 (1) 的一个典型选择是

$$f_{t:t \in \{q,k,v\}}(\mathbf{x}_i, i) := \mathbf{W}_{t:t \in \{q,k,v\}}(\mathbf{x}_i + \mathbf{p}_i), \quad (3)$$

其中, $\mathbf{p}_i \in \mathbb{R}^d$ 是一个 d 维向量, 其取决于标记 $\mathbf{x}_i$ 的位置。先前的工作 Devlin 等人 [2019], Lan 等人 [2020], Clark 等人 [2020], Radford 等人 [2019], Radford 和 Narasimhan [2018] 引入了使用一组可训练向量 $\mathbf{p}_i \in \{\mathbf{p}_t\}_{t=1}^L$ 的方法, 其中, L 是最大序列长度。Vaswani 等人 [2017] 提出使用正弦函数来生成 $\mathbf{p}_i$ 。

$$\begin{cases} \mathbf{p}_{i,2t} &= \sin(k/10000^{2t/d}) \\ \mathbf{p}_{i,2t+1} &= \cos(k/10000^{2t/d}) \end{cases} \quad (4)$$

其中 $\mathbf{p}_{i,2t}$ 是 d 维向量 $\mathbf{p}_i$ 的第 $2t^{th}$ 个元素。下一节中, 我们从正弦函数的角度说明我们提出的 RoPE 与这一直觉相关。然而, RoPE 并非将位置直接加到上下文表示中, 而是通过与正弦函数相乘来融入相对位置信息。

2.3 相对位置嵌入

Shaw 等人一文的作者 [2018] 对方程 (1) 采用了如下不同设置:

$$\begin{aligned} f_q(\mathbf{x}_m) &:= \mathbf{W}_q \mathbf{x}_m \\ f_k(\mathbf{x}_n, n) &:= \mathbf{W}_k(\mathbf{x}_n + \tilde{\mathbf{p}}_r^k) \\ f_v(\mathbf{x}_n, n) &:= \mathbf{W}_v(\mathbf{x}_n + \tilde{\mathbf{p}}_r^v) \end{aligned} \quad (5)$$

其中 $\tilde{\mathbf{p}}_r^k, \tilde{\mathbf{p}}_r^v \in \mathbb{R}^d$ 是可训练的相对位置嵌入。注意, $r = \text{clip}(m - n, r_{\min}, r_{\max})$ 表示位置 m 与 n 之间的相对距离。他们基于这样一个假设对相对距离进行了截断: 超过某一距离后, 精确的相对位置信息不再有用。在保持方程 (3) 形式不变的情况下, 作者 Dai 等人 [2019] 提出将方程 (2) 中的 $\mathbf{q}_m^\top \mathbf{k}_n$ 分解为

$$\mathbf{q}_m^\top \mathbf{k}_n = \mathbf{x}_m^\top \mathbf{W}_q^\top \mathbf{W}_k \mathbf{x}_n + \mathbf{x}_m^\top \mathbf{W}_q^\top \mathbf{W}_k \mathbf{p}_n + \mathbf{p}_m^\top \mathbf{W}_q^\top \mathbf{W}_k \mathbf{x}_n + \mathbf{p}_m^\top \mathbf{W}_q^\top \mathbf{W}_k \mathbf{p}_n, \quad (6)$$

其关键思想是将绝对位置嵌入 $\mathbf{p}_n$ 替换为其正弦编码的相对对应项 $\tilde{\mathbf{p}}_{m-n}$, 同时将第三项与第四项中的绝对位置 $\mathbf{p}_m$ 替换为与查询位置无关的两个可训练向量 $\mathbf{u}$ 和 $\mathbf{v}$ 。进一步地, 针对基于内容和基于位置的键向量 $\mathbf{x}_n$ 和 $\mathbf{p}_n$, 将 $\mathbf{W}_k$ 加以区分, 记为 $\mathbf{W}_k$ 和 $\mathbf{W}_k$, 从而得到:

$$\mathbf{q}_m^\top \mathbf{k}_n = \mathbf{x}_m^\top \mathbf{W}_q^\top \mathbf{W}_k \mathbf{x}_n + \mathbf{x}_m^\top \mathbf{W}_q^\top \widetilde{\mathbf{W}}_k \tilde{\mathbf{p}}_{m-n} + \mathbf{u}^\top \mathbf{W}_q^\top \mathbf{W}_k \mathbf{x}_n + \mathbf{v}^\top \mathbf{W}_q^\top \widetilde{\mathbf{W}}_k \tilde{\mathbf{p}}_{m-n} \quad (7)$$

值得注意的是, 通过设置 $f_v(\mathbf{x}_j) := \mathbf{W}_v \mathbf{x}_j$, 数值项中的位置信息被移除。随后的一些工作 Raffel 等人 [2020], He 等人 [2020], Ke 等人 [2020], Huang 等人 [2020] 通过仅将相对位置信息编码到注意权重中来沿用这些设置。然而, Raffel 等人 [2020] 的作者将 Equation (6) 改写为:

$$\mathbf{q}_m^\top \mathbf{k}_n = \mathbf{x}_m^\top \mathbf{W}_q^\top \mathbf{W}_k \mathbf{x}_n + b_{i,j} \quad (8)$$

其中 $b_{i,j}$ 是一个可训练的偏置。Ke 等人的作者 [2020] 研究了式 (6) 中的中间两项, 并发现绝对位置与词之间的相关性很弱。Raffel 等人的作者 [2020] 提出使用不同的投影矩阵来对一对词或位置进行建模。

$$\mathbf{q}_m^\top \mathbf{k}_n = \mathbf{x}_m^\top \mathbf{W}_q^\top \mathbf{W}_k \mathbf{x}_n + \mathbf{p}_m^\top \mathbf{U}_q^\top \mathbf{U}_k \mathbf{p}_n + b_{i,j} \quad (9)$$

He 等人的作者 [2020] 认为，两个标记的相对位置只能通过式 (6) 中的中间两项来完全建模。因此，绝对位置嵌入 p_m 和 p_n 被直接替换为相对位置嵌入 $\tilde{p}_{m-n}$ ：

$$q_m^\top k_n = x_m^\top W_q^\top W_k x_n + x_m^\top W_q^\top W_k \tilde{p}_{m-n} + \tilde{p}_{m-n}^\top W_q^\top W_k x_n \quad (10)$$

Radford 和 Narasimhan [2018] 对四种相对位置嵌入变体的比较表明，其中与式 (10) 相似的变体在其余三种中效率最高。一般而言，这些方法都试图在式 (2) 的自注意力设置下，基于式 (3) 的分解来修改式 (6)，该设置最初由 Vaswani 等人 [2017] 提出。它们通常通过将位置信息直接添加到上下文表示中来实现。不同的是，我们的方法旨在若干约束下，从式 (1) 推导出相对位置编码。接下来，我们将展示：通过将相对位置信息与上下文表示的旋转相结合，所推导的方法具有更强的可解释性。

3 所提方法

本节我们讨论所提出的旋转位置嵌入 (RoPE)。我们首先在第(3.1)节形式化相对位置编码问题，然后在第(3.2)节推导 RoPE，并在第(3.3)节研究其性质。

3.1 形式化

基于 Transformer 架构的语言建模通常通过自注意机制利用各个 Token 的位置信息。正如方程 (2) 所示， $q_m^\top k_n$ 通常能够在不同位置的 Token 之间传递知识。为纳入相对位置信息，我们要求查询 q_m 与键 k_n 的内积可由一个函数 g 表达，该函数仅以词嵌入 x_m 、 x_n 及其相对位置 $m-n$ 为输入变量。换言之，我们希望内积仅以相对形式编码位置信息：

$$\langle f_q(x_m, m), f_k(x_n, n) \rangle = g(x_m, x_n, m-n). \quad (11)$$

最终目标是找到一种等价的编码机制，使函数 $f_q(x_m, m)$ 和 $f_k(x_n, n)$ 符合上述关系。

3.2 旋转位置嵌入

3.2.1 二维情形

我们从一个维度为 $d=2$ 的简单情形开始。在此设置下，我们利用二维平面上向量的几何性质及其复数表示来证明（更多细节参见第(3.4.1)节）我们提出的公式化方程 (11) 的一个解为：

$$\begin{aligned} f_q(x_m, m) &= (W_q x_m) e^{im\theta} \\ f_k(x_n, n) &= (W_k x_n) e^{in\theta} \\ g(x_m, x_n, m-n) &= \text{Re}[(W_q x_m)(W_k x_n)^* e^{i(m-n)\theta}] \end{aligned} \quad (12)$$

其中 $\text{Re}[\cdot]$ 是复数的实部，且 $(W_k x_n)^*$ 表示 $(W_k x_n)$ 的共轭复数。 $\theta \in \mathbb{R}$ 是预设的非零常数。我们可以进一步将 $f_{\{q,k\}}$ 写成一个乘法矩阵：

$$f_{\{q,k\}}(x_m, m) = \begin{pmatrix} \cos m\theta & -\sin m\theta \\ \sin m\theta & \cos m\theta \end{pmatrix} \begin{pmatrix} W_{\{q,k\}}^{(11)} & W_{\{q,k\}}^{(12)} \\ W_{\{q,k\}}^{(21)} & W_{\{q,k\}}^{(22)} \end{pmatrix} \begin{pmatrix} x_m^{(1)} \\ x_m^{(2)} \end{pmatrix} \quad (13)$$

其中 $(x_m^{(1)}, x_m^{(2)})$ 在二维坐标中由 x_m 表示。类似地， g 可以视为一个矩阵，从而在二维情形下可以求解第 (3.1) 节中的形式化问题。具体而言，融入相对位置嵌入是很直接的：只需将仿射变换后的词嵌入向量按其位置索引的倍数角度旋转，从而解释旋转位置嵌入背后的直觉。

3.2.2 一般形式

为了将我们在二维中的结果推广到任意 $\mathbf{x}_i \in \mathbb{R}^d$ （其中 d 为偶数），我们将 d 维空间划分为 $d/2$ 个子空间，并借助内积的线性性将它们合并，从而把 $f_{\{q,k\}}$ 变为：

$$f_{\{q,k\}}(\mathbf{x}_m, m) = \mathbf{R}_{\Theta, m}^d \mathbf{W}_{\{q,k\}} \mathbf{x}_m \quad (14)$$

其中

$$\mathbf{R}_{\Theta, m}^d = \begin{pmatrix} \cos m\theta_1 & -\sin m\theta_1 & 0 & 0 & \cdots & 0 & 0 \\ \sin m\theta_1 & \cos m\theta_1 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & \cos m\theta_2 & -\sin m\theta_2 & \cdots & 0 & 0 \\ 0 & 0 & \sin m\theta_2 & \cos m\theta_2 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & \cos m\theta_{d/2} & -\sin m\theta_{d/2} \\ 0 & 0 & 0 & 0 & \cdots & \sin m\theta_{d/2} & \cos m\theta_{d/2} \end{pmatrix} \quad (15)$$

是具有预定义参数 $\Theta = \{\theta_i = 10000^{-2(i-1)/d}, i \in [1, 2, \dots, d/2]\}$ 的旋转矩阵。RoPE 的图示如图(1)所示。将我们的 RoPE 应用于式 (2) 中的自注意力，我们得到：

$$\mathbf{q}_m^\top \mathbf{k}_n = (\mathbf{R}_{\Theta, m}^d \mathbf{W}_q \mathbf{x}_m)^\top (\mathbf{R}_{\Theta, n}^d \mathbf{W}_k \mathbf{x}_n) = \mathbf{x}^\top \mathbf{W}_q \mathbf{R}_{\Theta, n-m}^d \mathbf{W}_k \mathbf{x}_n \quad (16)$$

其中 $\mathbf{R}_{\Theta, n-m}^d = (\mathbf{R}_{\Theta, m}^d)^\top \mathbf{R}_{\Theta, n}^d$ 。注意， $\mathbf{R}_{\Theta}^d$ 是一个正交矩阵，这确保了在位置信息编码过程中的稳定性。此外，由于 $\mathbf{R}_{\Theta}^d$ 的稀疏性，像式 (16) 那样直接进行矩阵乘法在计算上并不高效；我们在理论说明中提供了另一种实现。

不同于先前工作采用的加性位置嵌入方法（见式 (3) 到 (10)），我们的方法是乘性的。此外，与自注意力结合使用时，RoPE 通过旋转矩阵乘积自然地融合相对位置信息，而无需在加性位置编码的展开形式中修改各项。




图1：旋转位置嵌入（RoPE）的实现。

3.3 RoPE 的性质

长期衰减： 遵循 Vaswani 等人 [2017], 我们设定 $\theta_i = 10000^{-2i/d}$ 。可以证明，该设定具有长期衰减性质（更多细节参见第(3.4.3)节），这意味着当相对位置增大时，内积会衰减。这一性质与直觉相符：相对距离较远的一对Token之间应有更弱的联系。

RoPE 与线性注意： 自注意力可以被改写为一种更一般的形式。

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V})_m = \frac{\sum_{n=1}^N \text{sim}(\mathbf{q}_m, \mathbf{k}_n) \mathbf{v}_n}{\sum_{n=1}^N \text{sim}(\mathbf{q}_m, \mathbf{k}_n)}. \quad (17)$$

原始自注意力采用 $\text{sim}(\mathbf{q}_m, \mathbf{k}_n) = \exp(\mathbf{q}_m^\top \mathbf{k}_n / \sqrt{d})$ 。注意，原始自注意力需要对每一对 Token 计算查询和 key 的内积，其复杂度为平方级 $\mathcal{O}(N^2)$ 。遵循 Katharopoulos 等人 [2020], 线性注意将式 (17) 重写为

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V})_m = \frac{\sum_{n=1}^N \phi(\mathbf{q}_m)^\top \varphi(\mathbf{k}_n) \mathbf{v}_n}{\sum_{n=1}^N \phi(\mathbf{q}_m)^\top \varphi(\mathbf{k}_n)}, \quad (18)$$

其中 $\phi(\cdot)$ $\varphi(\cdot)$ 通常是非负函数。Katharopoulos 等人 [2020] 提出了 $\phi(x) = \varphi(x) = \text{elu}(x) + 1$ ，并首先利用矩阵乘法的结合律计算键和值之间的乘积。在 Shen 等人 [2021] 中，Softmax 函数被用于在内积之前分别对查询和键进行归一化，这等价于 $\phi(\mathbf{q}_i) = \text{Softmax}(\mathbf{q}_i)$ 和 $\phi(\mathbf{k}_j) = \exp(\mathbf{k}_j)$ 。有关线性注意的更多细节，建议读者参考原始论文。在本节中，我们重点讨论如何将 RoPE 与式 (18) 合并。由于 RoPE 通过旋转注入位置信息，从而保持隐藏表示的范数不变，我们可以通过将旋转矩阵与非负函数的输出相乘，将 RoPE 与线性注意合并。

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V})_m = \frac{\sum_{n=1}^N (\mathbf{R}_{\Theta, m}^d \phi(\mathbf{q}_m))^\top (\mathbf{R}_{\Theta, n}^d \varphi(\mathbf{k}_n)) \mathbf{v}_n}{\sum_{n=1}^N \phi(\mathbf{q}_m)^\top \varphi(\mathbf{k}_n)}. \quad (19)$$

值得注意的是，我们保持分母不变以避免被零除的风险，而分子中的求和可能包含负项。尽管式 (19) 中每个值 $\mathbf{v}_i$ 的权重并非严格意义上的概率归一化，我们认为这种计算仍然能够建模值的重要性。

3.4 理论解释

3.4.1 二维条件下 RoPE 的推导

在 $d = 2$ 的情况下，我们考虑两个词嵌入向量 $\mathbf{x}_q, \mathbf{x}_k$ ，它们分别对应于查询和键，以及它们各自的位置 m 和 n 。根据式 (1)，它们的位置编码形式为：

$$\begin{aligned} \mathbf{q}_m &= f_q(\mathbf{x}_q, m), \\ \mathbf{k}_n &= f_k(\mathbf{x}_k, n), \end{aligned} \quad (20)$$

其中， $\mathbf{q}_m$ 和 $\mathbf{k}_n$ 的下标表示所编码的位置相关信息。假设存在函数 g ，用于定义由 $f_{\{q, k\}}$ 产生的向量之间的内积：

$$\mathbf{q}_m^\top \mathbf{k}_n = \langle f_q(\mathbf{x}_m, m), f_k(\mathbf{x}_n, n) \rangle = g(\mathbf{x}_m, \mathbf{x}_n, n - m), \quad (21)$$

我们进一步要求满足以下初始条件：

$$\begin{aligned} \mathbf{q} &= f_q(\mathbf{x}_q, 0), \\ \mathbf{k} &= f_k(\mathbf{x}_k, 0), \end{aligned} \quad (22)$$

这可以理解为对不含位置信息的向量进行编码。基于这些设定，我们尝试求解 f_q, f_k 。首先，利用二维向量的几何意义及其复数对应形式，将式 (20) 和 (21) 中的函数分解为：

$$\begin{aligned} f_q(\mathbf{x}_q, m) &= R_q(\mathbf{x}_q, m) e^{i\Theta_q(\mathbf{x}_q, m)}, \\ f_k(\mathbf{x}_k, n) &= R_k(\mathbf{x}_k, n) e^{i\Theta_k(\mathbf{x}_k, n)}, \\ g(\mathbf{x}_q, \mathbf{x}_k, n - m) &= R_g(\mathbf{x}_q, \mathbf{x}_k, n - m) e^{i\Theta_g(\mathbf{x}_q, \mathbf{x}_k, n - m)}, \end{aligned} \quad (23)$$

其中， R_f, R_g 和 Θ_f, Θ_g 分别是 $f_{\{q, k\}}$ 和 g 的径向和角向分量。将它们代入方程 (21)，我们得到关系式：

$$\begin{aligned} R_q(\mathbf{x}_q, m) R_k(\mathbf{x}_k, n) &= R_g(\mathbf{x}_q, \mathbf{x}_k, n - m), \\ \Theta_k(\mathbf{x}_k, n) - \Theta_q(\mathbf{x}_q, m) &= \Theta_g(\mathbf{x}_q, \mathbf{x}_k, n - m), \end{aligned} \quad (24)$$

相应的初始条件为:

$$\begin{aligned}\mathbf{q} &= \|\mathbf{q}\|e^{i\theta_q} = R_q(\mathbf{x}_q, 0)e^{i\Theta_q(\mathbf{x}_q, 0)}, \\ \mathbf{k} &= \|\mathbf{k}\|e^{i\theta_k} = R_k(\mathbf{x}_k, 0)e^{i\Theta_k(\mathbf{x}_k, 0)},\end{aligned}\tag{25}$$

其中, $\|\mathbf{q}\|$ 、 $\|\mathbf{k}\|$ 和 θ_q 、 θ_k 是 $\mathbf{q}$ 和 $\mathbf{k}$ 在二维平面上的径向与角向部分。

接下来, 在式 (24) 中设定 $m = n$, 并考虑式 (25) 中的初始条件:

$$R_q(\mathbf{x}_q, m)R_k(\mathbf{x}_k, m) = R_g(\mathbf{x}_q, \mathbf{x}_k, 0) = R_q(\mathbf{x}_q, 0)R_k(\mathbf{x}_k, 0) = \|\mathbf{q}\|\|\mathbf{k}\|,\tag{26a}$$

$$\Theta_k(\mathbf{x}_k, m) - \Theta_q(\mathbf{x}_q, m) = \Theta_g(\mathbf{x}_q, \mathbf{x}_k, 0) = \Theta_k(\mathbf{x}_k, 0) - \Theta_q(\mathbf{x}_q, 0) = \theta_k - \theta_q.\tag{26b}$$

一方面, 由于, R_f 的一个直接解可以由式 (26a) 得出:

$$\begin{aligned}R_q(\mathbf{x}_q, m) &= R_q(\mathbf{x}_q, 0) = \|\mathbf{q}\| \\ R_k(\mathbf{x}_k, n) &= R_k(\mathbf{x}_k, 0) = \|\mathbf{k}\| \\ R_g(\mathbf{x}_q, \mathbf{x}_k, n - m) &= R_g(\mathbf{x}_q, \mathbf{x}_k, 0) = \|\mathbf{q}\|\|\mathbf{k}\|\end{aligned}\tag{27}$$

这表明径向函数 R_q 、 R_k 和 R_g 与位置信息无关。另一方面, 如式 (26b) 所示, $\Theta_q(\mathbf{x}_q, m) - \theta_q = \Theta_k(\mathbf{x}_k, m) - \theta_k$ 表明角向函数不依赖于查询和键, 我们将它们设为 $\Theta_f := \Theta_q = \Theta_k$; 且项 $\Theta_f(\mathbf{x}_{\{q,k\}}, m) - \theta_{\{q,k\}}$ 是位置 m 的函数, 并且与词嵌入 $\mathbf{x}_{\{q,k\}}$ 无关, 我们将其记为 $\phi(m)$, 从而得到:

$$\Theta_f(\mathbf{x}_{\{q,k\}}, m) = \phi(m) + \theta_{\{q,k\}},\tag{28}$$

进一步, 将 $n = m + 1$ 代入方程 (24), 并结合上述方程, 我们可以得到:

$$\phi(m + 1) - \phi(m) = \Theta_g(\mathbf{x}_q, \mathbf{x}_k, 1) + \theta_q - \theta_k,\tag{29}$$

由于 RHS 是一个与 m 无关的常数, $\phi(m)$ 在连续整数输入下产生一个等差数列

n:

$$\phi(m) = m\theta + \gamma,\tag{30}$$

其中 $\theta, \gamma \in \mathbb{R}$ 为常数, 且 θ 非零。总结方程 (27) 到 (30) 的解:

$$\begin{aligned}f_q(\mathbf{x}_q, m) &= \|\mathbf{q}\|e^{i\theta_q + m\theta + \gamma} = \mathbf{q}e^{i(m\theta + \gamma)}, \\ f_k(\mathbf{x}_k, n) &= \|\mathbf{k}\|e^{i\theta_k + n\theta + \gamma} = \mathbf{k}e^{i(n\theta + \gamma)}.\end{aligned}\tag{31}$$

注意, 我们没有对方程 (22) 中的 f_q 和 f_k 施加任何约束, 因此 $f_q(\mathbf{x}_m, 0)$ 和 $f_k(\mathbf{x}_n, 0)$ 可以自由选择。为了使我们的结果与方程 (3) 可比, 我们定义:

$$\begin{aligned}\mathbf{q} &= f_q(\mathbf{x}_m, 0) = \mathbf{W}_q \mathbf{x}_m, \\ \mathbf{k} &= f_k(\mathbf{x}_n, 0) = \mathbf{W}_k \mathbf{x}_n.\end{aligned}\tag{32}$$

然后, 我们只需在最终解的方程 (31) 中设置 $\gamma = 0$:

$$\begin{aligned}f_q(\mathbf{x}_m, m) &= (\mathbf{W}_q \mathbf{x}_m)e^{im\theta}, \\ f_k(\mathbf{x}_n, n) &= (\mathbf{W}_k \mathbf{x}_n)e^{in\theta}.\end{aligned}\tag{33}$$

3.4.2 旋转矩阵乘法的计算高效实现

利用 $\mathbf{R}_{\Theta, m}^d$ 在式 (15) 中的稀疏性, 对 $\mathbf{R}_{\Theta}^d$ 和 $\mathbf{x} \in \mathbb{R}^d$ 的乘法在计算上更高效的实现为:

$$\mathbf{R}_{\Theta, m}^d \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ \vdots \\ x_{d-1} \\ x_d \end{pmatrix} \otimes \begin{pmatrix} \cos m\theta_1 \\ \cos m\theta_1 \\ \cos m\theta_2 \\ \cos m\theta_2 \\ \vdots \\ \cos m\theta_{d/2} \\ \cos m\theta_{d/2} \end{pmatrix} + \begin{pmatrix} -x_2 \\ x_1 \\ -x_4 \\ x_3 \\ \vdots \\ -x_d \\ x_{d-1} \end{pmatrix} \otimes \begin{pmatrix} \sin m\theta_1 \\ \sin m\theta_1 \\ \sin m\theta_2 \\ \sin m\theta_2 \\ \vdots \\ \sin m\theta_{d/2} \\ \sin m\theta_{d/2} \end{pmatrix}\tag{34}$$




图2: RoPE 的长期衰减。

3.4.3 RoPE 的长期衰减

我们可以将向量 $\mathbf{q} = \mathbf{W}_q \mathbf{x}_m$ 和 $\mathbf{k} = \mathbf{W}_k \mathbf{x}_n$ 的元素成对分组，则式 (16) 中的 RoPE 内积可以写成复数乘法。

$$(\mathbf{R}_{\Theta, m}^d \mathbf{W}_q \mathbf{x}_m)^\top (\mathbf{R}_{\Theta, n}^d \mathbf{W}_k \mathbf{x}_n) = \text{Re} \left[\sum_{i=0}^{d/2-1} \mathbf{q}_{[2i:2i+1]} \mathbf{k}_{[2i:2i+1]}^* e^{i(m-n)\theta_i} \right] \quad (35)$$

其中 $\mathbf{q}_{[2i:2i+1]}$ 表示 $\mathbf{q}$ 的 $2i^{th}$ 到 $(2i+1)^{th}$ 项。记 $h_i = \mathbf{q}_{[2i:2i+1]} \mathbf{k}_{[2i:2i+1]}^*$ 和 $S_j = \sum_{i=0}^{j-1} e^{i(m-n)\theta_i}$ ，并令 $h_{d/2} = 0$ 和 $S_0 = 0$ ，我们可以使用 Abel 变换改写该求和

$$\sum_{i=0}^{d/2-1} \mathbf{q}_{[2i:2i+1]} \mathbf{k}_{[2i:2i+1]}^* e^{i(m-n)\theta_i} = \sum_{i=0}^{d/2-1} h_i (S_{i+1} - S_i) = - \sum_{i=0}^{d/2-1} S_{i+1} (h_{i+1} - h_i). \quad (36)$$

因此,

$$\begin{aligned} \left| \sum_{i=0}^{d/2-1} \mathbf{q}_{[2i:2i+1]} \mathbf{k}_{[2i:2i+1]}^* e^{i(m-n)\theta_i} \right| &= \left| \sum_{i=0}^{d/2-1} S_{i+1} (h_{i+1} - h_i) \right| \\ &\leq \sum_{i=0}^{d/2-1} |S_{i+1}| |h_{i+1} - h_i| \\ &\leq \left(\max_i |h_{i+1} - h_i| \right) \sum_{i=0}^{d/2-1} |S_{i+1}| \end{aligned} \quad (37)$$

请注意， $\frac{1}{d/2} \sum_{i=1}^{d/2} |S_i|$ 的数值会随着相对距离 $m-n$ 的增大而衰减，可通过设置 $\theta_i = 10000^{-2i/d}$ 实现，如图(2)所示。

4 实验与评估

我们按如下方式在多种自然语言处理任务上评估所提出的 RoFormer。我们在机器翻译任务上验证所提出方案的性能，见第 (4.1) 节。然后，我们在预训练阶段将我们的 RoPE 实现与 BERT (Devlin 等人 [2019]) 进行比较，见第 (4.2) 节。基于预训练模型，在第 (4.3) 节中，我们进一步在来自 GLUE 基准 (Singh 等人 [2018]) 的不同下游任务上开展评估。此外，我们使用所提出的 RoPE 与 PerFormer 的线性注意 (Choromanski 等人 [2020]) 进行实验在

表1: 所提出的 RoFormer 在 WMT 2014 英译德机器翻译任务 (Bojar 等人 [2014]) 上, 相比其基线 (Vaswani 等人 [2017]) , 取得了更高的 BLEU 分数。

模型	BLEU
Transformer 架构-baseVaswani 等人 [2017]	27.3
RoFormer	27.5

第(4.4)节。最后, 在第(4.5)节中包含了关于中文数据的额外测试。所有实验均在两台配备 4 块 V100 GPU 的云服务器上运行。

4.1 机器翻译

我们首先演示 RoFormer 在序列到序列语言翻译任务上的性能。

4.1.1 实验设置

我们选择标准的 WMT 2014 英语-德语数据集 Bojar 等人。 [2014], 其包含大约 450 万个句子对。我们将其与基于 Transformer 架构的基线模型进行比较, Vaswani 等人。 [2017]

4.1.2 实现细节

我们对基线模型的自注意力层进行了一些修改, Vaswani 等人。 [2017] 以使 RoPE 能够融入其学习过程。我们复现了英译德的设置, 采用基于联合源端与目标端的字节对编码(BPE)Sennrich 等人。 [2015]词表, 规模为三十七k。在评估期间, 通过对最后 5 个检查点求平均得到单个模型。结果使用束搜索, 束宽为 4, 长度惩罚为 0.6。我们在 PyTorch 中使用 fairseq 工具包(MIT 许可证)Ott 等人。 [2019]实现了该实验。我们的模型使用 Adam 优化器进行优化, 采用 $\beta_1 = 0.9, \beta_2 = 0.98$, 学习率从 $1e-7$ 线性增加到 $5e-4$, 随后按步数平方根的倒数成比例衰减。还采用了 0.1 的标签平滑。我们报告测试集上的 BLEU 分数, Papineni 等人。 [2002] 作为最终指标。

4.1.3 结果

我们在相同设置下训练了基线模型和我们的 RoFormer, 并在表(1)中报告结果。可以看出, 与基线 Transformer 架构相比, 我们的模型取得了更高的 BLEU 分数。

4.2 预训练语言建模

第二个实验旨在验证我们方案在学习上下文表示方面的性能。为此, 我们在预训练阶段用我们的 RoPE 替换了 BERT 原有的正弦位置编码。

4.2.1 实验设置

我们使用 Huggingface Datasets library (Apache License 2.0) 中的 BookCorpus Zhu et al. [2015] 和 Wikipedia Corpus Foundation [2021] 进行预训练。语料进一步按 8:2 的比例划分为训练集和验证集。我们使用训练过程中掩码语言建模 (MLM) 损失值作为评估指标。将知名的 BERT Devlin et al. [2019] 作为我们的基线模型。请注意, 我们在实验中使用的是 bert-base-uncased。

4.2.2 实现细节

对于 RoFormer, 我们将基线模型的自注意力模块中的正弦位置编码替换为我们提出的 RoPE, 并按公式 (16) 实现自注意力。我们以批大小 64、最大序列长度 512 训练 BERT 和 RoFormer, 持续 100k 步。采用 AdamW (Loshchilov and Hutter [2017]) 作为优化器, 学习率为 $1e-5$ 。

4.2.3 结果

预训练期间的 MLM 损失显示在图(3)的左图中。与原始 BERT 相比, RoFormer 收敛更快。




图3: 在语言建模预训练中的 RoPE 评估。左: BERT 和 RoFormer 的训练损失。右: PerFormer 在使用和不使用 RoPE 情况下的训练损失。

4.3 在 GLUE 基准任务上的微调

与先前的实验一致, 我们在各种 GLUE 基准任务上微调我们预训练 RoFormer 的权重, 以评估其在下游自然语言处理任务上的泛化能力。

4.3.1 实验设置

我们考察了来自 GLUE 基准的若干数据集, 即 MRPC Dolan and Brockett [2005], SST-2 Socher 等人 [2013], QNLI Rajpurkar 等人 [2016], STS-B Al-Natsheh [2017], QQP Chen 等人 [2018b] 以及 MNLI Williams 等人 [2018]。我们对 MRPC 和 QQP 数据集使用 F1-score, 对 STS-B 数据集使用 Spearman 相关系数, 其余使用准确率作为评估指标。

4.3.2 实现细节

我们使用 Huggingface Transformers 库 (Apache 许可证 2.0) Wolf et al. [2020] 对上述每个下游任务进行 3 个 epoch 的微调, 最大序列长度为 512, 批大小为 32, 学习率为 2、3、4、5e-5。遵循 Devlin 等人 [2019], 我们在验证集上报告最佳平均结果。

表2: 通过在下游 GLEU 任务上微调比较 RoFormer 和 BERT。

模型	MRPC 数据集 SST-2 数据集		QNLI 数据集 STS-B 数据集		QQP	MNLI 数据集(m/mm)
BERT Devlin 等 [2019]	88.9	93.5	90.5	85.8	71.2	84.6/83.4
RoFormer	89.5	90.7	88.0	87.0	86.4	80.2/79.8

4.3.3 结果

微调任务的评估结果见表(2)。如可见, RoFormer 在 6 个数据集上的 3 个上显著优于 BERT, 且提升幅度可观。

4.4 采用 RoPE 的 Performer

Performer Choromanski et al. [2020] 提出了一种替代的注意机制——线性注意, 其旨在避免随输入序列长度缩放的二次计算成本。正如在第(3.3)节所讨论的, 我们提出的 RoPE 可以轻松在 PerFormer 模型中实现相对位置编码, 同时在自注意力中保持其线性缩放的复杂度。我们通过语言建模的预训练任务展示其性能。

4.4.1 实现细节

我们在 Enwik8 数据集 Mahoney [2006], 上进行测试, 该数据集来自 English Wikipedia, 除英文文本外还包含标记、特殊字符以及其他语言的文本。我们将 RoPE 融入到 12 层基于字符的 PerFormer 中, 具有 768 维度和 12 个头²。为更好地说明 RoPE 的效果, 我们在相同设置下 (即学习率 $1e-4$ 、批大小 128 以及固定的最大序列长度 1024 等) 报告了带有和不带 RoPE 的预训练过程中损失曲线。

4.4.2 结果

如图(3)的右图所示, 在 Performer 中采用 RoPE, 在相同的训练步数下可以更快地收敛并得到更低的损失。这些改进, 连同其线性复杂度, 使 Performer 更具吸引力。

4.5 在中文数据上的评估

除了在英语数据上的实验之外, 我们还展示了中文数据上的更多结果。为验证 RoFormer 在长文本上的性能, 我们在长度超过 512 个字符的长文档上进行了实验。

4.5.1 实现

在这些实验中, 我们对 WoBERT Su [2020] 进行了若干修改, 用我们提出的 RoPE 替换了绝对位置嵌入。作为与其他中文预训练的基于Transformer的模型的交叉对比, 即 BERT Devlin et al. [2019], WoBERT Su [2020], 和 NEZHA Wei et al. [2019], , 我们在表 (3) 中列出了它们的分词级别和位置嵌入信息。

表3: 我们提出的 RoFormer 与其他在中文数据上的预训练模型的交叉对比。'abs' 和 'rel' 分别表示绝对位置嵌入和相对位置嵌入。

模型	BERT (Devlin 等人) [2019]	WoBERTSu [2020]	NEZHAWei et al. [2019]	RoFormer
标记化级别	char	word	char	word
位置嵌入	abs.	abs.	rel.	RoPE

4.5.2 预训练

我们在约 34GB 的数据上对 RoFormer 进行预训练, 这些数据收集自中文维基百科、新闻和论坛。为了使模型适应各种场景, 预训练分多个阶段进行, 并改变批大小和最大输入序列长度。如下表(4)所示, RoFormer 的准确率随着序列长度上界的增加而提升, 这表明 RoFormer 在处理长文本方面的能力。我们认为这归功于所提出的 RoPE 的优异泛化能力。

表4: RoFormer 在中文数据集上的预训练策略。训练过程被划分为若干连续阶段。在每个阶段, 我们使用特定的最大序列长度与批大小组合来训练模型。

阶段	最大序列长度	批大小	训练步数	Loss	准确率
1	512	256	200k	1.73	65.0%
2	1536	256	12.5k	1.61	66.8%
3	256	256	120k	1.75	64.6%
4	128	512	80k	1.83	63.4%
5	1536	256	10k	1.58	67.4%
6	512	512	30k	1.66	66.2%

4.5.3 下游任务与数据集

我们选择 Chinese AI 与 Law 2019年相似案例匹配 (CAIL2019-SCM) Xiao 等人 [2019] 数据集以作说明 RoForme 的能力 r 在处理长文本方面, 即语义文本匹配。CAIL2019-SCM 包含 8964 个三元组 s

²在本实验中, 我们采用来自 <https://github.com/lucidrains/performer-pytorch> 的代码 (MIT 许可证)

来自中国最高人民法院公布的案件。该输入三元组，用 $(A$ (输入令牌矩阵), 批次大小 和 C (专家容量)) 表示, 是对三个案件的事实描述。该任务是要在预定义的相似度度量下预测 $(A$ (输入令牌矩阵), 批次大小) 是否比 $(A$ (输入令牌矩阵), C (专家容量)) 更接近。需要注意的是, 由于文档长度 (即大多超过 512 个字符), 现有方法在 CAIL2019-SCM 数据集上大多难以取得显著表现。我们按照众所周知的 6:2:2 比例划分训练、验证和测试集。

4.5.4 结果

我们将预训练的 RoFormer 模型应用于 CAIL2019-SCM, 使用不同的输入长度。该模型与在相同预训练数据上训练的预训练 BERT 和 WoBERT 模型进行了对比, 如表(5)所示。在短文本截断 (即 512) 的情况下, RoFormer 的结果与 WoBERT 相当, 并略优于 BERT 的实现。然而, 当将最大输入文本长度提高到 1024 时, RoFormer 的表现优于 WoBERT, 绝对提升 1.5%。

表5: CAIL2019-SCM 任务的实验结果。第一列中的数字表示最大截断序列长度。结果以百分比准确率表示。

模型	验证	Test
BERT-512	64.13%	67.77%
WoBERT-512	64.07%	68.10%
RoFormer-512	64.13%	68.29%
RoFormer-1024	66.07%	69.79%

4.5.5 工作的局限性

尽管我们提供了理论依据以及令人鼓舞的实验理由, 但我们的方法仍受以下事实的限制:

- 尽管我们在数学上将相对位置关系表示为二维子空间下的旋转, 但对于为何它比采用其他位置编码策略的基线模型收敛更快, 仍缺乏充分的解释。
- 尽管我们已证明我们的模型在标记间乘积方面具有有利的长程衰减性质, 见第 (3.3) 节, 这与现有的位置编码机制相似; 并且尽管我们的模型在长文本上比同类模型表现出更优的性能, 我们仍未能给出令人信服的解释。

我们提出的 RoFormer 构建在基于 Transformer 架构的基础设施之上, 这需要用于预训练的硬件资源。

5 结论

在这项工作中, 我们提出了一种新的位置嵌入方法, 在自注意力中显式引入相对位置依赖, 以提升 Transformer 架构的性能。我们的理论分析表明, 相对位置可以在自注意力中通过向量乘积自然表述, 而绝对位置信息可通过旋转矩阵进行编码。此外, 我们从数学上阐明了该方法在应用于 Transformer 架构时的有利性质。最后, 在英文和中文基准数据集上的实验表明, 我们的方法在预训练中促进更快的收敛。实验结果还表明, 我们提出的 RoFormer 在长文本任务上能取得更好的性能。

参考文献

Jonas Gehring, Michael Auli, David Grangier, Denis Yarats 和 Yann N Dauphin. 卷积序列到序列学习。在国际机器学习会议, 页码 1243–1252。PMLR, 2017年。

Md. Amirul Islam, Sen Jia 和 Neil D. B. Bruce. 卷积神经网络编码了多少位置信息? *arXiv*, abs/2001.08248, 2020年。

阿希什·瓦斯瓦尼, 诺姆·沙齐尔, 妮基·帕尔马, 雅各布·乌什科雷特, 利昂·琼斯, Aidan NGomez, Lukasz Kaiser, 以及伊利亚·波洛苏欣。注意力机制就是全部所需。载于 I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan 和 R. Garnett (编辑), 神经信息处理系统进展,

- volume 30. Curran Associates, Inc., 2017. URL <https://proceedings.neurips.cc/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf>.
- J. Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *NAACL-HLT*, 2019.
- A. Radford, Jeffrey Wu, R. Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. 2019.
- Chulhee Yun, Srinadh Bhojanapalli, Ankit Singh Rawat, Sashank Reddi, and Sanjiv Kumar. Are transformers universal approximators of sequence-to-sequence functions? In *International Conference on Learning Representations*, 2020. URL <https://openreview.net/forum?id=ByxRMONTvr>.
- Zhenzhong Lan, Mingda Chen, Sebastian Goodman, Kevin Gimpel, Piyush Sharma, and Radu Soricut. Albert: A lite bert for self-supervised learning of language representations. In *International Conference on Learning Representations*, 2020. URL <https://openreview.net/forum?id=H1eA7AEtvS>.
- Kevin Clark, Minh-Thang Luong, Quoc V. Le, and Christopher D. Manning. ELECTRA: Pre-training text encoders as discriminators rather than generators. In *ICLR*, 2020. URL <https://openreview.net/pdf?id=r1xMH1BtvB>.
- A. Radford and Karthik Narasimhan. Improving language understanding by generative pre-training. 2018.
- Ankur P. Parikh, Oscar Täckström, Dipanjan Das, and Jakob Uszkoreit. A decomposable attention model for natural language inference. In *EMNLP*, 2016.
- Peter Shaw, Jakob Uszkoreit, and Ashish Vaswani. Self-attention with relative position representations. In *NAACL-HLT*, 2018.
- Cheng-Zhi Anna Huang, Ashish Vaswani, Jakob Uszkoreit, Noam Shazeer, I. Simon, C. Hawthorne, Andrew M. Dai, M. Hoffman, M. Dinculescu, and D. Eck. Music transformer. *arXiv: Learning*, 2018.
- Zihang Dai, Z. Yang, Yiming Yang, J. Carbonell, Quoc V. Le, and R. Salakhutdinov. Transformer-xl: Attentive language models beyond a fixed-length context. In *ACL*, 2019.
- Z. Yang, Zihang Dai, Yiming Yang, J. Carbonell, R. Salakhutdinov, and Quoc V. Le. Xlnet: Generalized autoregressive pretraining for language understanding. In *NeurIPS*, 2019.
- Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, W. Li, and Peter J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *J. Mach. Learn. Res.*, 21: 140:1–140:67, 2020.
- Guolin Ke, Di He, and T. Liu. Rethinking positional encoding in language pre-training. *ArXiv*, abs/2006.15595, 2020.
- Pengcheng He, Xiaodong Liu, Jianfeng Gao, and Weizhu Chen. DeBERTa: Decoding-enhanced bert with disentangled attention. *ArXiv*, abs/2006.03654, 2020.
- Zhiheng Huang, Davis Liang, Peng Xu, and Bing Xiang. Improve transformer models with better relative position embeddings. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 3327–3335, Online, November 2020. Association for Computational Linguistics. doi:10.18653/v1/2020.findings-emnlp.298. URL <https://www.aclweb.org/anthology/2020.findings-emnlp.298>.
- Xuanqing Liu, Hsiang-Fu Yu, Inderjit S. Dhillon, and Cho-Jui Hsieh. Learning to encode position for transformer with continuous dynamical model. In *Proceedings of the 37th International Conference on Machine Learning, ICML 2020, 13-18 July 2020, Virtual Event*, volume 119 of *Proceedings of Machine Learning Research*, pages 6327–6335. PMLR, 2020. URL <http://proceedings.mlr.press/v119/liu20n.html>.
- Tian Qi Chen, Yulia Rubanova, Jesse Bettencourt, and David Duvenaud. Neural ordinary differential equations. In Samy Bengio, Hanna M. Wallach, Hugo Larochelle, Kristen Grauman, Nicolò Cesa-Bianchi, and Roman Garnett, editors, *Advances in Neural Information Processing Systems 31: Annual Conference on Neural Information Processing Systems 2018, NeurIPS 2018, December 3-8, 2018, Montréal, Canada*, pages 6572–6583, 2018a. URL <https://proceedings.neurips.cc/paper/2018/hash/69386f6bb1dfed68692a24c8686939b9-Abstract.html>.
- Benyou Wang, Donghao Zhao, Christina Lioma, Qiuchi Li, Peng Zhang, and Jakob Grue Simonsen. Encoding word order in complex embeddings. In *International Conference on Learning Representations*, 2020. URL <https://openreview.net/forum?id=Hke-WTVtwr>.
- Angelos Katharopoulos, Apoorv Vyas, Nikolaos Pappas, and François Fleuret. Transformers are rnns: Fast autoregressive transformers with linear attention. In *International Conference on Machine Learning*, pages 5156–5165. PMLR, 2020.
- Zhuoran Shen, Mingyuan Zhang, Haiyu Zhao, Shuai Yi, and Hongsheng Li. Efficient attention: Attention with linear complexities. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 3531–3539, 2021.

- Amapreet Singh, Julian Michael, Felix Hill, Omer Levy, and Samuel Bowman. Glue: A multi-task benchmark and analysis platform for natural language understanding. 04 2018.
- Krzysztof Choromanski, Valerii Likhoshesterov, David Dohan, Xingyou Song, A. Gane, Tamás Sarlós, Peter Hawkins, J. Davis, Afroz Mohiuddin, Lukasz Kaiser, David Belanger, Lucy J. Colwell, and Adrian Weller. Rethinking attention with performers. *ArXiv*, abs/2009.14794, 2020.
- Ondrej Bojar, Christian Buck, Christian Federmann, Barry Haddow, Philipp Koehn, Johannes Leveling, Christof Monz, Pavel Pecina, Matt Post, Herve Saint-Amand, Radu Soricut, Lucia Specia, and Alevs Tamchyna. Findings of the 2014 workshop on statistical machine translation. pages 12–58, 06 2014. doi:10.3115/v1/W14-3302.
- Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. 08 2015.
- Myle Ott, Sergey Edunov, Alexei Baevski, Angela Fan, Sam Gross, Nathan Ng, David Grangier, and Michael Auli. fairseq: A fast, extensible toolkit for sequence modeling. pages 48–53, 01 2019. doi:10.18653/v1/N19-4009.
- Kishore Papineni, Salim Roukos, Todd Ward, and Wei Jing Zhu. Bleu: a method for automatic evaluation of machine translation. 10 2002. doi:10.3115/1073083.1073135.
- Yukun Zhu, Ryan Kiros, Richard Zemel, Ruslan Salakhutdinov, Raquel Urtasun, Antonio Torralba, and Sanja Fidler. Aligning books and movies: Towards story-like visual explanations by watching movies and reading books. In *arXiv preprint arXiv:1506.06724*, 2015.
- Wikimedia Foundation. Wikimedia downloads, <https://dumps.wikimedia.org>, 2021.
- Ilya Loshchilov and Frank Hutter. Decoupled Weight Decay Regularization. *arXiv e-prints*, art. arXiv:1711.05101, November 2017.
- William B. Dolan and Chris Brockett. Automatically constructing a corpus of sentential paraphrases. In *Proceedings of the Third International Workshop on Paraphrasing (IWP2005)*, 2005. URL <https://www.aclweb.org/anthology/I05-5002>.
- Richard Socher, A. Perelygin, J.Y. Wu, J. Chuang, C.D. Manning, A.Y. Ng, and C. Potts. Recursive deep models for semantic compositionality over a sentiment treebank. *EMNLP*, 1631:1631–1642, 01 2013.
- Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev, and Percy Liang. Squad: 100,000+ questions for machine comprehension of text. pages 2383–2392, 01 2016. doi:10.18653/v1/D16-1264.
- Hussein Al-Natsheh. Udl at semeval-2017 task 1: Semantic textual similarity estimation of english sentence pairs using regression model over pairwise features. 08 2017.
- Z. Chen, H. Zhang, and L. Zhang, X. and Zhao. Quora question pairs., 2018b. URL <https://www.kaggle.com/c/quora-question-pairs>.
- Adina Williams, Nikita Nangia, and Samuel Bowman. A broad-coverage challenge corpus for sentence understanding through inference. pages 1112–1122, 01 2018. doi:10.18653/v1/N18-1101.
- Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest, and Alexander M. Rush. Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 38–45, Online, October 2020. Association for Computational Linguistics. URL <https://www.aclweb.org/anthology/2020.emnlp-demos.6>.
- Matt Mahoney. Large text compression benchmark, <http://www.matmahoney.net/dc/text.html>, 2006.
- Jianlin Su. Wobert: Word-based chinese bert model - zhuiyiai. Technical report, 2020. URL <https://github.com/ZhuiyiTechnology/WoBERT>.
- Victor Junqiu Wei, Xiaozhe Ren, Xiaoguang Li, Wenyong Huang, Yi Liao, Yasheng Wang, Jiashu Lin, Xin Jiang, Xiao Chen, and Qun Liu. Nezha: Neural contextualized representation for chinese language understanding. 08 2019.
- Chaojun Xiao, Haoxi Zhong, Zhipeng Guo, Cunchao Tu, Zhiyuan Liu, Maosong Sun, Tianyang Zhang, Xianpei Han, Zhen hu, Heng Wang, and Jianfeng Xu. Cail2019-scm: A dataset of similar case matching in legal domain. 11 2019.