

DeepSeekMoE: 迈向专家混合语言模型的终极专家专精

Damai Dai^{*1,2}, Chengqi Deng¹, Chenggang Zhao^{*1,3}, R.X. Xu¹, Huazuo Gao¹, Deli Chen¹, Jiashi Li¹, Wangding Zeng¹, Xingkai Yu^{*1,4}, Y. Wu¹, Zhenda Xie¹, Y.K. Li¹, Panpan Huang¹, Fuli Luo¹, Chong Ruan¹, Zhifang Sui², Wenfeng Liang¹

¹DeepSeek-AI²北京大学多媒体信息处理国家重点实验室³清华大学交叉信息研究院⁴
南京大学计算机软件新技术国家重点实验室{daidamai, szf}@pku.edu.cn,
{wenfeng.liang}@deepseek.com
<https://github.com/deepseek-ai/DeepSeek-MoE>

摘要

在大语言模型时代, 专家混合 (MoE) 是一种在扩展模型参数时用于管理计算成本的有前景的架构。然而, 诸如 GShard 等常规专家混合架构采用在 N 名专家中激活 top- K 的方式, 难以保障专家专精性, 即每个专家都能获取非重叠且聚焦的知识。对此, 我们提出了

DeepSeekMoE 架构, 旨在实现极致的专家专精。它包含两项核心策略: (1) 将专家细粒度地划分为 mN 个, 并从中激活 mK 个, 从而能更灵活地组合已激活的专家; (2) 将 K_s 个专家隔离为共享专家, 旨在捕获共性知识并缓解已路由专家中的冗余。从规模较小的 20 亿参数起步, 我们证明 DeepSeekMoE 20 亿的性能可与 GShard 29 亿相当, 而后者的专家参数数量和计算量为 $1.5\times$ 。此外, DeepSeekMoE 20 亿的性能几乎接近具有相同总参数数量的稠密对应模型, 而后者构成 MoE 模型的性能上限。随后, 我们将 DeepSeekMoE 扩展到 160 亿参数, 结果表明其性能可与 LLaMA2 70 亿相当, 而计算量仅约为 40%。此外, 我们将 DeepSeekMoE 进一步扩展到 1450 亿参数的初步尝试也持续验证了其相较于 GShard 架构的显著优势, 并显示其性能可与 DeepSeek 670 亿相当, 而所需计算量仅为 28.5% (maybe even 18.2%)。

1. 引言

近期的研究与实践经验证明, 在有充足训练数据的前提下, 通过增加参数规模与计算预算来扩展语言模型可以得到显著更强的模型 (Brown 等, 2020 年; Hoffmann 等, 2022 年; OpenAI, 2023 年; Touvron 等, 2023a)。然而, 我们也必须认识到, 将模型扩展到极大规模的尝试会伴随着极其高昂的计算成本。鉴于巨大的成本, 专家混合 (MoE) 架构 (Jacobs 等, 1991 年; Jordan 和 Jacobs, 1994 年; Shazeer 等, 2017 年) 已成为一种流行的解决方案。它可以

*在 DeepSeek-AI 实习期间完成的贡献。




图 1 | DeepSeekMoE 160亿与开源模型在开源大型语言模型排行榜上的比较。红色虚线是基于除 DeepSeekMoE 160亿外所有模型的数据点线性拟合得到。DeepSeekMoE 160亿在激活参数数量相近的模型上始终大幅领先，并且与 LLaMA2 70亿（其激活参数约为其 2.5 倍）表现相当。

在保持计算成本处于相对适中的水平的同时，实现参数规模的扩展。最近，专家混合（MoE）架构在 Transformer 模型（Vaswani 等，2017 年）中的应用，使将语言模型扩展到相当规模的尝试取得了成功（Du 等，2022 年；Fedus 等，2021 年；Lepikhin 等，2021 年；Zoph，2022 年），并伴随着显著的性能提升。这些成果凸显了专家混合语言模型的巨大潜力与前景。

尽管 MoE 架构具有可观的潜力，现有 MoE 架构可能面临知识混杂性与知识冗余的问题，从而限制了专家专精化，即每个专家获得非重叠且聚焦的知识。传统的 MoE 架构将 Transformer 架构中的前馈网络（FFN）替换为 MoE 层。每个 MoE 层由多个专家组成，每个专家在结构上与标准的前馈网络相同，并且每个标记会被分配给一个（Fedus 等，2021 年）或两个（Lepikhin 等，2021 年）专家。该架构呈现出两个潜在问题：（1）**Knowledge Hybridity**：现有 MoE 实践通常只采用有限数量的专家（例如 8 或 16），因此分配给某一特定专家的标记很可能涵盖多样化的知识。于是，该指定专家会倾向于在其参数中汇聚类型迥异的知识，而这些知识难以同时被利用。（2）**Knowledge Redundancy**：被分配到不同专家的标记可能需要共同的知识。结果，多个专家可能在各自的参数中收敛到获取相同的共享知识，从而导致专家参数的冗余。这些问题共同阻碍了现有 MoE 实践中的专家专精化，使其无法达到 MoE 模型在理论上的性能上限。

针对上述问题，我们提出 DeepSeekMoE，这是一种专为实现极致专家专精而设计的创新性专家混合架构。我们的架构包含两项主要策略：（1）**细粒度专家划分**：在保持参数数量不变的情况下，我们通过切分

前馈网络的中间表示隐藏维度。相应地，在保持计算成本不变的前提下，我们也会激活更多细粒度的专家，以实现对已激活专家更灵活、可适配的组合。细粒度专家划分使多样化的知识能够被更细致地分解，并更精确地学习到不同专家中，从而使每个专家保持更高程度的专精。此外，在已激活专家的组合上增加的灵活性也有助于更准确、更有针对性的知识获取。（2）**共享专家隔离**：我们将某些专家隔离为始终被激活的共享专家，旨在捕获并整合跨不同上下文的共知识。通过将共知识压缩到这些共享专家中，其他已路由专家之间的冗余将得到缓解。这可以提升参数效率，并确保每个已路由专家通过专注于独特方面而保持专精。这些在 DeepSeekMoE 中的架构创新为训练参数高效的专家混合语言模型提供了机会，在该模型中每个专家都高度专精。

从适度的缩放起步（2B 参数），我们验证了 DeepSeek-MoE 架构的优势。我们在覆盖多种任务的 12 个零样本或小样本基准上进行了评测。实证结果表明，DeepSeekMoE 2B 以显著优势超过了 GShard 2B（Lepikhin 等，2021 年），甚至可与 GShard 2.9B 相媲美，后者是一个更大的专家混合模型，具有 1.5 $\times$ 倍的专家参数和计算。值得注意的是，我们发现，在参数量相当的情况下，DeepSeekMoE 2B 的性能几乎接近其稠密对应模型，而该稠密模型构成了专家混合语言模型的严格上限。为获得更深入的洞见，我们对 DeepSeekMoE 的专家专门化进行了详尽的消融研究与分析。这些研究验证了细粒度专家分割与共享专家隔离的有效性，并提供了支持 DeepSeekMoE 能实现高度专家专门化这一论断的实证证据。

借助我们的架构，我们随后将模型参数扩展到 160 亿，并在包含 2T 个标记的大规模语料库上训练 DeepSeekMoE 160 亿。评测结果表明，仅使用约 40% 的计算，DeepSeekMoE 160 亿即可达到与 DeepSeek 70 亿（DeepSeek-AI，2024 年）相当的性能，后者是在同一 2T 语料库上训练的稠密模型。我们还将 DeepSeekMoE 与开源模型进行了比较，评测表明，DeepSeekMoE 160 亿在与具有相似激活参数数量的模型相比时始终以较大优势胜出，并且其性能与 LLaMA2 70 亿（Touvron 等，2023b）相当，而后者大约具有其 2.5 倍的激活参数。图 1 展示了开源大型语言模型排行榜¹上的评测结果。此外，我们为对齐进行了有监督微调（SFT），将该模型转化为聊天模型。评测结果显示，在聊天设置中，DeepSeekMoE Chat 160 亿同样取得了与 DeepSeek Chat 70 亿和 LLaMA2 SFT 70 亿相当的性能。在这些结果的鼓舞下，我们进一步进行了一项初步尝试，将 DeepSeekMoE 缩放至 1450 亿。实验结果仍然一致验证了其相较于 GShard 架构的显著优势。此外，它仅使用 28.5%（甚至可能为 18.2%）的计算，就表现出与 DeepSeek 670 亿相当的性能。

我们的贡献总结如下：

- **架构创新**。我们提出了 DeepSeekMoE，这是一种创新的专家混合架构，旨在实现极致的专家专门化，其采用两项主要策略：细粒度专家分割与共享专家隔离。
- **实证验证**。我们进行了大量实验，以实证验证 DeepSeekMoE 架构的有效性。实验结果验证了高度的

¹https://huggingface.co/spaces/HuggingFaceH4/open_llm_leaderboard

DeepSeekMoE 2B 中专家专门化水平，并表明 DeepSeekMoE 2B 几乎可以接近 MoE 模型的性能上界

- **可扩展性。** 我们将 DeepSeekMoE 扩展用于训练一个160亿参数的模型，并表明仅用约40%的计算量，DeepSeekMoE 160亿模型即可达到与 DeepSeek 70亿和 LLaMA2 70亿相当的性能。我们还进行了将 DeepSeekMoE 扩展至1450亿的初步尝试，突出其相较于 GShard 架构的持续优势，并展示了与 DeepSeek 670亿相当的性能。
- **专家混合的对齐。** 我们在 DeepSeekMoE 160亿模型上成功进行了监督微调，构建了一个对齐的聊天模型，展示了 DeepSeekMoE 160亿的适应性和多样性。
- **公开发布。** 秉持开放研究的精神，我们向公众发布了 DeepSeekMoE 160亿的模型检查点。值得注意的是，该模型可在内存为40GB的单张GPU上部署，无需量化。

2. 预备知识：面向 Transformer 模型的专家混合

我们首先介绍一种在 Transformer 架构的语言模型中常用的通用专家混合架构。标准的 Transformer 架构语言模型通过堆叠 L 层标准的 Transformer 块构建，其中每个块可表示为：

$$\mathbf{u}_{1:T}^l = \text{Self-Att}(\mathbf{h}_{1:T}^{l-1}) + \mathbf{h}_{1:T}^{l-1}, \quad (1)$$

$$\mathbf{h}_t^l = \text{FFN}(\mathbf{u}_t^l) + \mathbf{u}_t^l, \quad (2)$$

其中 T 表示序列长度， $\text{Self-Att}(\cdot)$ 表示自注意力模块， $\text{FFN}(\cdot)$ 表示前馈网络 (FFN)， $\mathbf{u}_t^l$ ：
 $\mathbf{u}_t^l \in \mathbb{R}^{T \times d}$ 表示在第 l 个注意模块之后所有 Token 的隐藏状态，而 $\mathbf{h}_t^l \in \mathbb{R}^d$ 表示第 t 个标记在第 l 个 Transformer 块之后的输出隐藏状态。为简洁起见，上述公式中省略了层归一化。

构建专家混合语言模型的一种典型做法，是在 Transformer 架构中按指定间隔用 MoE 层替换前馈网络 (Du 等, 2022年; Fedus 等, 2021年; Lepikhin 等, 2021年; Zoph, 2022年)。一个 MoE 层由多个专家组成，其中每个专家在结构上与标准的前馈网络完全相同。随后，每个标记将被分配给一个 (Fedus 等, 2021年) 或两个 (Lepikhin 等, 2021年) 专家。若将第 l 个前馈网络替换为一个 MoE 层，其输出隐藏状态 $\mathbf{h}_t^l$ 的计算可表示为：

$$\mathbf{h}_t^l = \sum_{i=1}^N \left(g_{i,t} \text{FFN}_i(\mathbf{u}_t^l) \right) + \mathbf{u}_t^l, \quad (3)$$

$$g_{i,t} = \begin{cases} s_{i,t}, & s_{i,t} \in \text{Topk}(\{s_{j,t} | 1 \leq j \leq N\}, K), \\ 0, & \text{otherwise}, \end{cases} \quad (4)$$

$$s_{i,t} = \text{Softmax}_i(\mathbf{u}_t^{lT} \mathbf{e}_i^l), \quad (5)$$

其中， N 表示专家总数，前馈网络 $(\cdot)$ 是第 i 个专家前馈网络 (FFN)， $g_{i,t}$ 表示第 i 个专家的门控值， $s_{i,t}$ 表示标记到专家的亲和度， $\text{Topk}(\cdot, K)$ 表示包含 K 个最高亲和度分数的集合，这些分数是针对第 t 个标记与所有 N 个专家计算得到的，并且 $\mathbf{e}_i^l$ 是第 i 个专家在第 l 层中的质心。请注意， $g_{i,t}$ 是稀疏的，这表示在 N 个门控值中只有 K 个为非零。这种稀疏性保证了 MoE 层内的计算效率，即每个标记只会被分配到并仅在 K 个专家中进行计算。另外，在上述公式中，我们为简洁起见省略了层归一化操作。




图 2 | DeepSeekMoE 示意图。子图 (a) 展示了采用常规 top-2路由策略的 MoE层。子图 (b) 展示了细粒度专家分割策略。随后，子图 (c) 展示了集成共享专家隔离策略，从而完成 DeepSeekMoE 架构。值得注意的是，在这三种架构中，专家参数数量和计算成本保持不变。

3. DeepSeekMoE 架构

在第2节概述的通用专家混合架构之上，我们提出了 DeepSeekMoE，其专门旨在挖掘专家特化的潜力。正如图2所示，我们的架构包含两项主要策略：细粒度专家划分和共享专家隔离。这两种策略均旨在提升专家特化程度。

3.1. 细粒度专家划分

在专家数量受限的场景中，分配给某个专家的 Token 更可能覆盖多样的知识类型。因此，该指定专家会倾向于在其参数中学习截然不同的知识类型，而这些知识难以被同时利用。然而，如果每个标记可以已路由到更多专家，多样的知识就有可能被拆解，并分别在不同的专家中学习。在此背景下，每个专家仍能保持较高的专家专精水平，使跨专家的知识分布更加集中。

为实现这一目标，同时保持专家参数数量和计算成本不变，我们以更细的粒度划分专家。更细的专家划分使已激活专家的组合更加灵活、可适配。具体而言，在图2(a)所示的典型专家混合架构之上，我们通过将FFN 中间维度缩小至原来的 $\frac{1}{m}$ 倍，把每个专家前馈网络（FFN）划分为 m 个更小的专家。由于每个专家变得更小，为了保持相同的计算成本，我们相应地将激活的专家数量增加到 m 倍，如图2(b)所示。借助这种细粒度

的专家划分，MoE层的输出可以表示为：

$$\mathbf{h}_t^l = \sum_{i=1}^{mN} \left(g_{i,t} \text{FFN}_i \left(\mathbf{u}_t^l \right) \right) + \mathbf{u}_t^l, \quad (6)$$

$$g_{i,t} = \begin{cases} s_{i,t}, & s_{i,t} \in \text{Topk}(\{s_{j,t} | 1 \leq j \leq mN\}, mK), \\ 0, & \text{otherwise}, \end{cases} \quad (7)$$

$$s_{i,t} = \text{Softmax}_i \left(\mathbf{u}_t^{lT} \mathbf{e}_i^l \right), \quad (8)$$

其中，专家参数的总数等于标准前馈网络中参数数量的 N 倍，且 mN 表示细粒度专家的总数。采用细粒度专家分割策略后，非零门控的数量也将增加到 mK 。

从组合的角度看，细粒度专家分割策略显著提升被激活专家的组合灵活性。作为一个示例，我们考虑 $N = 16$ 的情况。典型的top-2路由策略可以产生 $\binom{16}{2} = 120$ 种可能的组合。相比之下，如果每个专家被拆分为4个更小的专家，则细粒度路由策略可以产生 $\binom{64}{8} = 4,426,165,368$ 种潜在的组合。组合灵活性的激增提高了实现更精确、更有针对性的知识获取的潜力。

3.2. 共享专家隔离

在常规路由策略下，分配给不同专家的标记可能需要某些共同的知识或信息。因此，多个专家可能在各自的参数中趋同地获取共享知识，从而导致专家参数出现冗余。然而，如果设置专门用于在不同上下文中捕获并整合共通知识的共享专家，其他已路由专家之间的参数冗余将得到缓解。这种冗余的缓解将有助于得到一个参数效率更高、专家更专精的模型。

为此，除细粒度专家划分策略外，我们进一步将 K_s 名专家隔离出来，作为共享专家。不论路由器模块如何，每个标记都会被确定性地分配给这些共享专家。为保持恒定的计算成本，其他已路由专家中被激活的专家数量将减少 K_s ，如图2(c)所示。集成共享专家隔离策略后，在完整的 DeepSeekMoE 架构中，一个MoE层可表述如下：

$$\mathbf{h}_t^l = \sum_{i=1}^{K_s} \text{FFN}_i \left(\mathbf{u}_t^l \right) + \sum_{i=K_s+1}^{mN} \left(g_{i,t} \text{FFN}_i \left(\mathbf{u}_t^l \right) \right) + \mathbf{u}_t^l, \quad (9)$$

$$g_{i,t} = \begin{cases} s_{i,t}, & s_{i,t} \in \text{Topk}(\{s_{j,t} | K_s + 1 \leq j \leq mN\}, mK - K_s), \\ 0, & \text{otherwise}, \end{cases} \quad (10)$$

$$s_{i,t} = \text{Softmax}_i \left(\mathbf{u}_t^{lT} \mathbf{e}_i^l \right). \quad (11)$$

最后，在 DeepSeekMoE 中，共享专家的数量为 K_s ，已路由专家的总数为 $mN - K_s$ ，非零门控的数量为 $mK - K_s$ 。

值得注意的是，共享专家隔离的原型可归功于 Rajbhandari 等（2022年）。关键区别在于，他们从工程角度提出了这一策略，而我们则从算法角度加以阐述。

3.3. 负载均衡考量

自动学习的路由策略可能会遇到负载不均衡问题，主要表现为两个显著缺陷。首先，存在路由坍塌的风险（Shazeer 等，2017 年），即模型总是只选择少量专家，导致其他专家无法得到充分训练。其次，如果专家分布在多个设备上，负载不均衡会加剧计算瓶颈。

专家级平衡损失。 为缓解路由崩溃的风险，我们也采用专家级平衡损失。该平衡损失的计算如下：

$$\mathcal{L}_{\text{ExpBal}} = \alpha_1 \sum_{i=1}^{N'} f_i P_i, \quad (12)$$

$$f_i = \frac{N'}{K'T} \sum_{t=1}^T \mathbb{1}(\text{Token } t \text{ selects Expert } i), \quad (13)$$

$$P_i = \frac{1}{T} \sum_{t=1}^T s_{i,t}, \quad (14)$$

其中， α_1 是一个称为专家级平衡因子的超参数， N' 等于 $(mN - K_s)$ ， K' 等于 $(mK - K_s)$ ，为简洁起见。 $\mathbb{1}(\cdot)$ 表示指示函数。

设备级平衡损失。 除了专家级平衡损失之外，我们还引入了设备级平衡损失。当旨在缓解计算瓶颈时，没有必要在专家级强制严格的均衡约束，因为过多的负载均衡约束会损害模型性能。相反，我们的主要目标函数是确保各设备之间的计算均衡。若将所有已路由的专家划分为 D 个组 $\{E_1, E_2, \dots, E_D\}$ ，并将每个组部署在单个设备上，则设备级平衡损失的计算如下：

$$\mathcal{L}_{\text{DevBal}} = \alpha_2 \sum_{i=1}^D f'_i P'_i, \quad (15)$$

$$f'_i = \frac{1}{|\mathcal{E}_i|} \sum_{j \in \mathcal{E}_i} f_j, \quad (16)$$

$$P'_i = \sum_{j \in \mathcal{E}_i} P_j, \quad (17)$$

其中 α_2 是一个称为设备级平衡因子的超参数。在实践中，我们将专家级平衡因子设置得较小以缓解路由坍塌的风险，同时将设备级平衡因子设置得较大，以促进各设备间的计算更加均衡。

4. 验证实验

4.1. 实验设置

4.1.1. 训练数据与分词

我们的训练数据采样自由 DeepSeek-AI 构建的大规模多语言语料库。该语料库主要以英语和中文为主，但也涵盖其他语言。

其来源多样，包括网页文本、数学材料、代码脚本、已发表文献以及其他各类文本材料。出于验证实验的目的，我们从语料库中抽取包含 100B 个标记的子集来训练我们的模型。对于分词，我们使用 HuggingFace Tokenizer² tools 在训练语料库的一个更小子集上训练字节对编码（BPE）（Sennrich 等，2016年）分词器。在验证实验中，我们准备了一个词表大小为 8K 的分词器，且在训练更大的模型时将进一步缩放词表大小。

4.1.2. 基础设施

我们基于 HAI-LLM（High-Flyer，2023年）开展实验。该高效且轻量级的训练框架集成了多种并行策略，包括张量并行（Korthikanti 等，2023年；Narayanan 等，2021年；Shoeybi 等，2019年）、ZeRO 数据并行（Rajbhandari 等，2020年）、PipeDream 流水线并行（Harlap 等，2018年），以及更具体地，通过结合数据并行和张量并行实现的专家并行（Lepikhin 等，2021年）。为优化性能，我们使用 CUDA 和 Triton（Tilletet 等，2019年）开发了用于门控算法的 GPU 内核，并对不同专家的线性层上的计算进行了融合。

所有实验均在配备英伟达 A100 或 H800 GPU 的集群上进行。A100 集群中的每个节点包含 8 块 GPU，并通过 NVLink 桥两两互连。H800 集群的每个节点同样配备 8 块 GPU，节点内通过 NVLink 和 NVSwitch 进行互连。对于 A100 和 H800 集群，使用 InfiniBand 互连以促进跨节点通信。

4.1.3. 超参数

模型设置。 在验证实验中，我们将 Transformer 架构的层数设为 9，隐藏维度设为 1280。我们采用多头注意机制，总共有 10 个注意头，每个头的维度为 128。在初始化方面，所有可学习参数随机初始化，标准差为 0.006。我们用 MoE 层替换所有前馈网络，并确保专家参数的总数等于标准前馈网络的 16 倍。此外，我们将已激活的专家参数（包括共享专家参数和已激活的已路由专家参数）保持为标准前馈网络的 2 倍。在该配置下，每个 MoE 模型的总参数约为 2B，已激活的参数数量约为 0.3B。

训练设置。 我们采用 AdamW 优化器（Loshchilov and Hutter，2019年），将超参数设为 $\beta_1 = 0.9$ 、 $\beta_2 = 0.95$ ，以及权重_衰减 = 0.1。学习率采用预热与分段衰减策略。起始阶段，学习率在前 2K 步内从 0 线性升至最大值。随后，在训练步数的 80% 处将学习率乘以 0.316，并在 90% 处再次乘以 0.316。用于验证实验的最大学习率设为 1.08×10^{-3} ，梯度裁剪范数设为 1.0。批大小设为 2K，在最大序列长度为 2K 的情况下，每个训练批次包含 4M 标记。相应地，总训练步数设为 25,000，以达到 100B 训练标记。由于训练数据充足，我们在训练期间不使用 Dropout（随机失活）。鉴于模型规模较小，包括专家参数在内的所有参数均部署在单张 GPU 设备上，以避免计算不均衡。相应地，我们在训练过程中不丢弃任何标记，也不使用设备级

²<https://github.com/huggingface/tokenizers>

平衡损失。为了防止路由崩塌，我们将专家级平衡因子设为 0.01。

为便于阅读，我们还在附录A中给出了针对不同规模的 DeepSeekMoE 的超参数概览表。

4.1.4. 评估基准

我们在覆盖多种任务类型的广泛基准上进行了评估。我们将这些基准列举如下。

语言建模。 对于语言建模，我们在 Pile 的测试集上对模型进行评估（Gao 等人，2020年），评估指标为交叉熵损失。

语言理解与推理。 对于语言理解与推理，我们考虑 HellaSwag（Zellers 等人，2019年）、PIQA（Bisk 等人，2020年）、ARC-challenge 和 ARC-easy（Clark 等人，2018年）。这些任务的评估指标是准确率。

阅读理解。 对于阅读理解，我们使用 RACE-high 和 RACE-middle（Lai 等人，2017年），评估指标是准确率。

Code Generation. 对于代码生成，我们在 HumanEval（Chen 等人，2021年）和 MBPP（Austin 等人，2021年）上评估模型。评估指标为 Pass@1，表示仅一次生成尝试的通过率。

Closed-Book Question Answering. 对于闭卷问答，我们采用 Trivi-aQA（Joshi 等人，2017年）和 NaturalQuestions（Kwiatkowski 等人，2019年）。评估指标为精确匹配（EM）率。

4.2. 评估

Baselines. 包括 DeepSeekMoE 在内，我们在验证实验中比较了五个模型。**Dense** 表示一个标准的稠密 Transformer 架构语言模型，总参数为 2亿。**HashLayer**（Roller 等人，2021年）是一种基于 top-1 哈希路由的专家混合架构，总参数为 20亿、激活参数为 2亿，与稠密基线对齐。**Switch Trans-former**（Fedus 等人，2021年）是另一种知名的基于 top-1 可学习路由的专家混合架构，其总参数与激活参数与 Hash Layer 相同。**GShard**（Lepikhin 等人，2021年）采用 top-2 可学习路由策略，总参数为 20亿、激活参数为 3亿，因为相比 top-1 路由方法会多激活一个专家。**DeepSeekMoE** 具有 1 个共享专家和 63 个已路由专家，其中每个专家的规模为标准前馈网络的 0.25 倍。包括 DeepSeekMoE 在内，所有对比模型共享相同的训练语料和训练超参数。所有对比专家混合模型的总参数数量相同，且 GShard 的激活参数数量与 DeepSeekMoE 相同。

结果。 我们在表1中展示评测结果。对于所有展示的模型，我们报告了在 100B Token 上训练后的最终评测结果。根据该表，我们有如下观察：（1）在稀疏架构且具有更多总参数的情况下，Hash Layer

指标	#Shot	稠密	Hash 层	Switch 模型	GShard	DeepSeekMoE
# 参数总数	N/A	0.2B	2.0B	2.0B	2.0B	2.0B
# 激活参数数	N/A	0.2B	0.2B	0.2B	0.3B	0.3B
每 2K Token 的 FLOPs	N/A	2.9T	2.9T	2.9T	4.3T	4.3T
# 训练 Token 数	N/A	100B	100B	100B	100B	100B
Pile (损失)	N/A	2.060	1.932	1.881	1.867	1.808
HellaSwag (准确率)	零样本	38.8	46.2	49.1	50.5	54.8
PIQA (准确率)	零样本	66.8	68.4	70.5	70.6	72.3
ARC-easy (准确率)	零样本	41.0	45.3	45.9	43.9	49.4
ARC-challenge (Acc.)	零样本	26.0	28.2	30.2	31.6	34.3
RACE-middle (Acc.)	五样本	38.8	38.8	43.6	42.1	44.0
RACE-high (Acc.)	5-shot	29.0	30.0	30.9	30.4	31.7
HumanEval (Pass@1)	0-shot	0.0	1.2	2.4	3.7	4.9
MBPP (Pass@1)	3-shot	0.2	0.6	0.4	0.2	2.2
TriviaQA (EM)	5-shot	4.9	6.5	8.9	10.2	16.6
NaturalQuestions (EM)	5-shot	1.4	1.4	2.5	3.2	5.7

表 1 | 验证实验的评估结果。**加粗**字体表示最佳。与其他专家混合架构相比，DeepSeekMoE 展现出显著的性能优势。

以及 Switch Transformer 在相同数量的激活参数下取得的性能显著强于稠密基线。（2）与 Hash Layer 和 Switch Transformer 相比，GShard 拥有更多激活参数，并且其性能略优于 Switch Transformer。（3）在总参数和激活参数数量相同的情况下，DeepSeekMoE 相对于 GShard 展现出压倒性优势。这些结果展示了我们的 DeepSeekMoE 架构在现有的专家混合架构中的优越性。

4.3. DeepSeekMoE 与 MoE 模型的上界高度一致

我们已经证明，DeepSeekMoE 的性能优于稠密基线和其他专家混合架构。为更精确地理解 DeepSeekMoE 的性能，我们将其与总参数量或被激活参数更多的更大基线方法进行比较。这些比较使我们能够估计 GShard 或稠密基线要达到与 DeepSeekMoE 等效性能所需的模型规模。

与 GShard 的比较×1.5. 表2展示了 DeepSeekMoE 与一个更大的 GShard 模型之间的比较，该模型的专家规模为 1.5 倍，因此其专家参数和专家计算也均为 1.5 倍。总体而言，我们观察到 DeepSeekMoE 的性能与 GShard×1.5 相当，这突显了 DeepSeekMoE 架构所固有的显著优势。除了与 GShard×1.5 的比较之外，我们还在附录 B 中展示了与 GShard×1.2 的比较。

此外，我们将 DeepSeekMoE 的总参数数量增加到 13.3B，并将其与分别具有 15.9B 和 19.8B 总参数的 GShard×1.2 和 GShard×1.5 进行比较。我们发现，在更大的缩放规模下，DeepSeekMoE 甚至可以显著地优于 GShard×1.5。这些

指标	# 示例数	GShard×1.5	稠密×16	DeepSeekMoE
相对专家规模	N/A	1.5	1	0.25
# 专家	N/A	0 + 16	16 + 0	1 + 63
# 激活的专家	N/A	0 + 2	16 + 0	1 + 7
# 专家总参数量	N/A	2.83B	1.89B	1.89B
# 已激活专家参数	N/A	0.35B	1.89B	0.24B
每 2K Token 的 FLOPs	N/A	5.8T	24.6T	4.3T
# 训练 Token	N/A	100B	100B	100B
Pile (损失)	N/A	1.808	1.806	1.808
HellaSwag (准确率)	零样本	54.4	55.1	54.8
PIQA (准确率)	零样本	71.1	71.9	72.3
ARC-easy (准确率)	0-shot	47.3	51.9	49.4
ARC-challenge (准确率)	0-shot	34.1	33.8	34.3
RACE-middle (准确率)	5-shot	46.4	46.3	44.0
RACE-high (准确率)	5-shot	32.4	33.0	31.7
HumanEval (Pass@1)	0-shot	3.0	4.3	4.9
MBPP (Pass@1)	3-shot	2.6	2.2	2.2
TriviaQA (EM)	5-shot	15.7	16.5	16.6
NaturalQuestions (EM)	5-shot	4.7	6.3	5.7

表 2 | DeepSeekMoE、更大的 GShard 模型和更大的稠密模型之间的比较。在“# Experts”一行中， $a + b$ 表示 a 共享专家和 b 已路由专家。在“# Activated Experts”一行中， $a + b$ 表示 a 已激活的共享专家和 b 已激活的已路由专家。DeepSeekMoE 的性能可与包含 1.5 倍专家参数和计算的 GShard 模型相当。此外，DeepSeekMoE 的性能几乎接近具有 16 倍前馈网络参数的稠密模型，这为 MoE 模型的模型容量设定了上界。

结果也在附录 B 中提供。

与稠密模型的比较×16. 表2还展示了 DeepSeekMoE 与更大的稠密模型之间的比较。为保证公平比较，我们不采用注意与前馈网络参数之间广泛使用的比例（1:2）。相反，我们配置了 16 个共享专家，每个专家的参数数量与标准前馈网络相同。该架构模拟了一个具有标准前馈网络参数 16 倍的稠密模型。根据该表，我们发现 DeepSeekMoE 的性能几乎接近稠密×16，其在模型容量方面为 MoE 模型设定了严格上界。这些结果表明，至少在约 **20** 亿参数和 **1000** 亿训练 **Token** 的规模下，**DeepSeekMoE** 的性能与 **MoE** 模型的理论上限高度一致。此外，我们在附录 B 中提供了与稠密×4 的更多比较。

4.4. 消融研究

为了证明细粒度专家分割和共享专家隔离策略的有效性，我们对 DeepSeekMoE 进行了消融实验，并在图3中给出结果。为了公平比较，我们确保纳入比较的所有模型具有




图 3 | DeepSeekMoE 的消融研究。为便于展示，性能按最佳性能进行了归一化。所有对比模型具有相同的参数数量和被激活的参数数量。我们可以发现，细粒度专家分割与共享专家隔离均有助于提升整体性能。

相同的总参数量和激活参数量。

共享专家隔离。 为评估共享专家隔离策略的影响，我们在 GShard 的基础上将一个专家隔离为共享专家。从图3可以观察到，相较于 GShard，有意隔离一个共享专家在大多数基准上带来了更好的性能。这些结果支持该命题：共享专家隔离策略有助于提升模型性能。

细粒度专家分割。 为评估细粒度专家分割策略的有效性，我们通过将专家进一步细分来进行更为细致的比较。具体而言，我们将每个专家分割为 2 个或 4 个更小的专家，总计 32 (1 共享 + 31 已路由) 或 64 (1 共享 + 63 已路由) 个专家。图3揭示出一致的趋势：随着专家分割粒度的持续细化，整体模型性能持续提升。这些发现为细粒度专家分割策略的有效性提供了实证支撑。

共享专家与已路由专家的比例。 此外，我们探究共享专家与已路由专家的最佳比例。在总专家数为 64 的最细粒度设置下，并保持总专家数和已激活专家数不变，我们尝试将 1、2 和 4 个专家划为共享专家。我们发现，共享专家与已路由专家的不同配比对性能影响不大，且 1、2、4 个共享专家分别得到 Pile 损失 1.808、1.806、1.811。鉴于 1:3 的比例在 Pile 损失上略优，在扩展 DeepSeekMoE 时，我们将共享专家与已激活的已路由专家的比例保持为 1:3。

4.5. 专家专门化分析

在本节中，我们对 DeepSeekMoE 2B 的专家专门化进行实证分析。本节中的 DeepSeekMoE 2B 指的是表1中报告的模型，即总参数为 20 亿，包含 1 个共享专家，并在 63 个已路由专家中有 7 个被激活。




图 4 | 针对不同比例的被禁用 Top-k 已路由专家的 Pile 损失。值得注意的是，DeepSeekMoE 对被禁用的 Top-k 已路由专家的比例更为敏感，这表明在 DeepSeekMoE 中已路由专家之间的冗余更低。

DeepSeekMoE 在已路由专家间表现出更低的冗余。 为评估已路由专家之间的冗余，我们禁用不同比例的 Top-k 已路由专家，并评估 Pile 损失。具体而言，对每个标记，我们对具有最高路由概率的部分专家进行掩蔽，然后从剩余的已路由专家中选择 Top-k 专家。为公平起见，我们将 DeepSeekMoE 与 GShard×1.5 进行比较，因为在未禁用任何专家时，它们的 Pile 损失相同。如图4所示，与 GShard×1.5 相比，DeepSeekMoE 对禁用 Top-k 已路由专家更为敏感。这种敏感性表明 DeepSeekMoE 的参数冗余更低，因为每个已路由专家都更难以被替代。相反，GShard×1.5 的专家参数冗余更高，因此在禁用 Top-k 已路由专家时，它可以缓冲性能下降。

共享专家不可被已路由专家取代。 为了研究 DeepSeekMoE 中共享专家的作用，我们将其禁用，并额外启用一个已路由专家。在 Pile 上的评测显示，尽管我们保持相同的计算成本，Pile 损失显著上升，从 1.808 增加到 2.414。该结果凸显了共享专家的重要功能，并表明共享专家捕获了未与已路由专家共享的基础且关键的知识，因此无法被后者取代。

DeepSeekMoE 更准确地获取知识。 为了验证我们关于在组合已激活专家方面更高的灵活性有助于更准确且更具针对性的知识获取这一主张，我们探究 DeepSeekMoE 是否能以更少的已激活专家获取所需知识。具体而言，我们将已激活的已路由专家数量从3到7进行变化，并评估相应的 Pile 损失。如图5所示，即使仅有




图 5 | DeepSeekMoE 中随不同数量的已激活的已路由专家变化的 Pile 损失。仅激活 4 个已路由专家时，DeepSeekMoE 的 Pile 损失可与 GShard 相当。




图 6 | 在仅一半已激活专家（从头训练）的情况下，对比 GShard 与 DeepSeekMoE。具有相同的专家总参数且仅一半的已激活专家参数时，DeepSeekMoE 仍优于 GShard。

4 个已路由专家被激活，DeepSeekMoE 也能实现与 GShard 相当的 Pile 损失。这一观察支持了这样的观点：DeepSeekMoE 能更准确且更高效地获取所需知识。

受这些发现的鼓舞，为了更严格地验证 DeepSeekMoE 的专家专门化与精准的知识获取，我们从头开始训练了一个新的模型。该模型由 1 个共享专家和 63 个已路由专家组成，其中仅有 3 个已路由专家被激活。图 6 所示的评测结果表明，即便在总专家参数相同且被激活的专家参数仅为一半的情况下，DeepSeekMoE 仍优于 GShard。这凸显了 DeepSeekMoE 利用专家参数

更高效，即被激活的专家中的有效参数比例远高于 GShard。

5. 扩展至 DeepSeekMoE16B

借助 DeepSeekMoE 架构，我们将专家混合模型扩展到具有 16B 总参数的更大规模，并在 2T 个标记上进行训练。我们的结果表明，与 LLaMA2 70亿 相比，DeepSeekMoE 16B 仅用约 40% 的计算即可取得更优的性能。

5.1. 实验设置

5.1.1. 训练数据与分词

我们从第 4.1.1 小节所述的相同语料库中抽取训练数据。不同于验证实验，我们抽取了更大的数据量，共 2T 个标记，与 LLaMA2 70亿 的训练 Token 数量保持一致。我们还使用 HuggingFace Tokenizer 工具训练一个 BPE tokenizer，但对于 DeepSeekMoE 16B，将词表大小设为 100K。

5.1.2. 超参数

模型设置。 对于 DeepSeekMoE 16B，我们将 Transformer 架构的层数设为 28，隐藏维度为 2048。我们采用多头注意力机制，总计 16个注意力头，每个头的维度为 128。在初始化方面，所有可学习参数均以标准差 0.006 随机初始化。除第一层外，我们将所有前馈网络替换为 MoE层，因为我们观察到第一层的负载均衡状态收敛得尤其慢。每个MoE层由 2 个共享专家和 64 个已路由专家组成，其中每个专家的规模为标准前馈网络的 0.25 倍。每个标记将被路由到这 2 个共享专家以及 64 个已路由专家中的 6 个。由于过小的专家规模可能会降低计算效率，我们未采用更细的专家划分粒度。在超过 16B 的更大缩放下，仍可采用更细的粒度。在我们的配置下，DeepSeekMoE 16B 的总参数量约为 16.4B，激活的参数数量约为 2.8B。

训练设置。 我们采用 AdamW 优化器 (Loshchilov and Hutter, 2019年)，并将超参数设为 $\beta_1 = 0.9$ 、 $\beta_2 = 0.95$ ，以及 `weight_decay` = 0.1。学习率也采用预热加分段衰减策略进行调度：最初，学习率在前 2K 步线性地从 0 增加到最大值；随后，在训练步数的 80% 处，学习率乘以 0.316，并在训练步数的 90% 处再次乘以 0.316。DeepSeekMoE 16B 的最大学习率设为 4.2×10^{-4} ，梯度裁剪范数设为 1.0。批大小设为 4.5K，在最大序列长度为 4K 的情况下，每个训练批次包含 18M Token。相应地，总训练步数设为 106,449，以达到 2T 训练 Token。由于训练数据充足，我们在训练期间不使用 Dropout（随机失活）。我们利用流水线并行将模型的不同层部署在不同的设备上，对于每一层，所有专家都将部署在同一设备上。因此，我们在训练中也不丢弃任何 Token，且不采用设备级平衡损失。为防止路由坍塌，我们将专家级平衡因子设为 0.001，因为我们发现，在我们的并行化策略下，更高的专家级平衡因子并不能提升计算效率，反而会损害模型性能。

5.1.3. 评估基准

除验证实验使用的基准外，我们还纳入了更多基准，以进行更全面的评估。我们将与验证实验所用基准的差异说明如下。

语言建模。 对于语言建模，我们也在 Pile (Gao et al., 2020年) 的测试集上对模型进行评估。由于 DeepSeekMoE 16B 使用的 tokenizer 与 LLaMA2 70亿所使用的不同，为了公平比较，我们采用每字节比特数 (BPB) 作为评估指标。

阅读理解。 对于阅读理解，我们另外考虑 DROP (Dua et al., 2019年)。评估指标为完全匹配 (EM) 率。

数学推理。 对于数学推理，我们另外纳入 GSM8K (Cobbe et al., 2021年) 和 MATH (Hendrycks et al., 2021年)，并使用 EM 作为评估指标。

多学科多项选择题。 对于多学科多项选择题，我们还在 MMLU (Hendrycks et al., 2020年) 上对模型进行评估。评估指标为准确率。

消歧。 对于消歧，我们另外考虑 Winogrande 数据集 (Sakaguchi 等人, 2019年)，其评估指标为准确率。

中文基准。 由于 DeepSeekMoE 16B 在双语语料库上进行了预训练，我们也在四个中文基准上对其进行评估。CLUEWSC (Xu 等人, 2020年) 是一个中文消歧基准。CEval (Huang 等人, 2023年) 和 CMMLU (Li 等人, 2023年) 是两个与 MMLU 形式相似的中文多学科多项选择基准。CHID (Zheng 等人, 2019年) 是一个中文成语填空基准，旨在评估对中国文化的理解。上述中文基准的评估指标为准确率或 EM。

Open LLM Leaderboard. 我们基于内部评估框架对上述所有基准进行评估。为公平且便捷地将 DeepSeekMoE 16B 与开源模型进行比较，我们还在 Open LLM Leaderboard 上对 DeepSeekMoE 16B 进行了额外评估。Open LLM Leaderboard 是由 HuggingFace 支持的公共排行榜，包含六个任务：ARC (Clark 等人, 2018年)、HellaSwag (Zellers 等人, 2019年)、MMLU (Hendrycks 等人, 2020年)、TruthfulQA (Lin 等人, 2022年)、Winogrande 数据集 (Sakaguchi 等人, 2019年) 以及 GSM8K (Cobbe 等人, 2021年)。

5.2. 评估

5.2.1. 与 DeepSeek 70亿的内部比较

我们首先在内部对 DeepSeekMoE 16B 和 DeepSeek 70亿 (DeepSeek-AI, 2024年) 进行比较，后者是一个拥有 69亿 参数的稠密语言模型。为确保公平，两个模型都在同一语料库上进行训练，包含 2T 个标记。这使我们能够在不受训练数据影响的情况下，准确评估我们专家混合架构的有效性。

指标	# 示例数	DeepSeek7B (稠密)	DeepSeekMoE16B
# 参数总量	N/A	6.9B	16.4B
# 已激活参数量	N/A	6.9B	2.8B
每 4K Token 的 FLOPs	N/A	183.5T	74.4T
# 训练 Token	N/A	2T	2T
Pile (BPB)	N/A	0.75	0.74
HellaSwag (准确率)	零样本	75.4	77.1
PIQA (准确率)	零样本	79.2	80.2
ARC-easy (准确率)	零样本	67.9	68.1
ARC-challenge (准确率)	零样本	48.1	49.8
RACE-middle (准确率)	5-shot	63.2	61.9
RACE-high (准确率)	5-shot	46.5	46.4
DROP (EM)	1-shot	34.9	32.9
GSM8K (EM)	8-shot	17.4	18.8
MATH (EM)	4-shot	3.3	4.3
HumanEval (Pass@1)	0-shot	26.2	26.8
MBPP (Pass@1)	3-shot	39.0	39.2
TriviaQA (EM)	5-shot	59.7	64.8
NaturalQuestions (EM)	5-shot	22.2	25.5
MMLU (Acc.)	5-shot	48.2	45.0
Winogrande 数据集 (准确率)	0-shot	70.5	70.2
CLUEWSC (EM)	5-shot	73.1	72.1
CEval (准确率)	5-shot	45.0	40.6
CMMLU (准确率)	5-shot	47.2	42.5
CHID (准确率)	0-shot	89.3	89.4

表 3 | DeepSeek 70亿与 DeepSeekMoE 160亿的比较。Bold 字体表示最佳或接近最佳。仅用 40.5% 的计算，DeepSeekMoE 160亿达到与 DeepSeek 70亿相当的性能。

评估结果见 表3，得到如下观察：（1）总体而言，只需约 40% 的计算量，DeepSeekMoE 16B 便可获得与 DeepSeek 70亿 相当的性能。（2）DeepSeekMoE 16B 在语言建模以及诸如 Pile、HellaSwag、TriviaQA 和 NaturalQuestions 等知识密集型任务上展现出显著优势。鉴于在 专家混合 模型 中，前馈网络参数远重于注意参数，这些结果与“Transformer 模型中的前馈网络具备知识记忆能力”（Dai 等，2022a）的命题相一致。（3）与在其他任务上的出色表现相比，DeepSeekMoE 在处理多项选择任务方面表现出局限性。这种不足源于 DeepSeekMoE 16B 中有限的注意参数（DeepSeekMoE 16B 只有约 5亿 注意 参数，而 DeepSeek 70亿 有 25亿 注意 参数）。我们此前对 DeepSeek 70亿 的研究表明，注意容量与多项选择任务的性能呈正相关。例如，配备多查询注意机制的 DeepSeek 70亿 MQA（Shazeer，2019年）在类 MMLU 的任务中也表现不佳。此外，为了更全面地理解训练过程

关于 DeepSeekMoE 16B，我们还在附录C中提供了 DeepSeekMoE 16B 与 DeepSeek 70亿（稠密）在训练期间的基准曲线，供参考。

关键是，由于 DeepSeekMoE 16B 的参数数量适中，它可以在内存为 40GB 的 GPU 上进行单设备部署。通过适当的算子优化，它的推理速度可达到 70亿稠密模型的近 2.5 倍。

指标	# 示例数	LLaMA2 70亿	DeepSeekMoE16B
# 参数总数	N/A	6.7B	16.4B
# 已激活参数量	N/A	6.7B	2.8B
每 4K Token 的 FLOPs	N/A	187.9T	74.4T
# 训练 Token	N/A	2T	2T
Pile (BPB)	N/A	0.76	0.74
HellaSwag (准确率)	零样本	75.6	77.1
PIQA (准确率)	零样本	78.0	80.2
ARC-easy (准确率)	零样本	69.1	68.1
ARC-challenge (准确率)	零样本	49.0	49.8
RACE-middle (准确率)	五样本	60.7	61.9
RACE-high (准确率)	五样本	45.8	46.4
DROP (EM)	1-shot	34.0	32.9
GSM8K (EM)	8-shot	15.5	18.8
MATH (EM)	4-shot	2.6	4.3
HumanEval (Pass@1)	0-shot	14.6	26.8
MBPP (Pass@1)	3-shot	21.8	39.2
TriviaQA (EM)	5-shot	63.8	64.8
NaturalQuestions (EM)	5-shot	25.5	25.5
MMLU (准确率)	5-shot	45.8	45.0
Winogrande 数据集 (准确率)	0-shot	69.6	70.2
CLUEWSC (EM)	5-shot	64.0	72.1
CEval (准确率)	5-shot	33.9	40.6
CMMLU (准确率)	5-shot	32.6	42.5
CHID (准确率)	零样本	37.9	89.4

表 4 | LLaMA2 70亿与 DeepSeekMoE 16B 的比较。仅使用 39.6% 的计算量，DeepSeekMoE 16B 在大多数基准上优于 LLaMA2 70亿。

5.2.2. 与开源模型的比较

与 LLaMA2 7B 的内部比较。 在开源模型领域，我们主要将 DeepSeekMoE 16B 与 LLaMA2 7B (Touvron 等, 2023b) 进行比较，这是一款知名且强大的开源语言模型，参数数量为67亿。DeepSeekMoE 16B 和 LLaMA2 7B 均在 2T 个标记上进行预训练。与 LLaMA2 7B 相比，DeepSeekMoE 的总参数量为其的 245%，但仅需 39.6% 的计算。我们在内部基准上的结果见表4，得到以下观察。（1）在所评估的基准中，在仅约 40% 的计算情况下，DeepSeekMoE 16B 在大多数基准上优于 LLaMA2 7B。（2）DeepSeekMoE 16B 的数学推理与代码生成能力

强于 LLaMA2 7B，这归因于我们预训练语料中更为丰富的数学与代码相关文本。（3）鉴于我们的预训练语料包含中文文本，DeepSeekMoE 16B 在中文基准上相较 LLaMA2 7B 具有显著的性能优势。（4）尽管用于训练的英文文本较少，DeepSeekMoE 16B 在英文理解或知识密集型基准上仍可达到与 LLaMA2 7B 相当或更好的性能，这展示了 DeepSeekMoE 16B 的卓越能力。

在 Open LLM Leaderboard 上的评测。除了我们的内部评测之外，我们还在 Open LLM Leaderboard 上对 DeepSeekMoE 16B 进行评测，并将其与其他开源模型进行比较。除 LLaMA2 70亿 外，我们还纳入了更广泛的开源模型，包括 LLaMA 70亿（Touvron 等，2023a）、Falcon 70亿（Almazrouei 等，2023年）、GPT-J 6B（Wang 和 Komatsuzaki，2021年）、RedPajama-INCITE 70亿和 3B（Together-AI，2023年）、Open LLaMA 70亿和 3B（Geng 和 Liu，2023年）、OPT 2.7B（Zhang 等，2022年）、Pythia 2.8B（Biderman 等，2023年）、GPT-neo 2.7B（Black 等，2021年）以及 BLOOM 3B（Scao 等，2022年）。如图1所示的评测结果表明，DeepSeekMoE 16B 一直以较大优势超过激活参数规模相近的模型。此外，它的性能与 LLaMA2 70亿 相当，而后的激活参数约为前者的 2.5 倍。

6. DeepSeekMoE16B 的对齐

以往研究表明，MoE 模型通常不会从微调中获得显著收益（Artetxe 等人，2022年；Fedus 等人，2021年）。然而，Shen 等人（2023年）的研究表明，MoE 模型确实能够从指令微调中受益。为评估 DeepSeekMoE 16B 是否从微调中获益，我们基于 DeepSeekMoE 16B 进行监督微调，构建了一个对话模型。实验结果显示，DeepSeekMoE Chat 16B 的性能也可与 LLaMA2 SFT 70亿 和 DeepSeek Chat 70亿 相媲美。

6.1. 实验设置

训练数据。为了训练该对话模型，我们在内部整理的数据上进行监督微调（SFT），包含 140 万个训练样本。该数据集覆盖了广泛的类别，包括数学、代码、写作、问答、推理、摘要生成，以及更多。我们的 SFT 训练数据大多为英文和中文，使该对话模型在双语场景下具有良好的适用性和通用性。

超参数。在监督式微调期间，我们将批大小设为1024个样本，并使用 AdamW 优化器（Loshchilov and Hutter，2019年）训练8个epoch。我们采用最大序列长度为4K，并将训练样本尽可能稠密地打包直到达到序列长度上限。对于监督式微调，我们不使用 Dropout（随机失活），而是将学习率设为常数 10^{-5} 不采用任何学习率调度策略。

评测基准。为了评估聊天模型，我们采用与第5.1.3节相似的基准，并做如下调整：(1) 我们排除 Pile（Gao 等，2020年），因为聊天模型很少用于纯语言建模。(2) 我们排除

CHID (Zheng et al., 2019年), 由于观察到结果的稳定性较差, 妨碍得出扎实的结论。(3)我们另外纳入 BBH (Suzgunet al., 2022年), 以提供对聊天模型推理能力更全面的评估。

指标	# 示例数	LLaMA2 SFT 70亿	DeepSeek Chat 70亿	DeepSeekMoE Chat 160亿
# 总参数量	N/A	6.7B	6.9B	164亿
# 激活参数量	N/A	6.7B	6.9B	2.8B
每 4K Token 的 FLOPs	N/A	187.9T	183.5T	74.4T
HellaSwag (准确率)	零样本	67.9	71.0	72.2
PIQA (准确率)	零样本	76.9	78.4	79.7
ARC-easy (准确率)	零样本	69.7	70.2	69.9
ARC-challenge (准确率)	零样本	50.8	50.2	50.0
BBH (EM)	3-shot	39.3	43.1	42.2
RACE-middle (Acc.)	5-shot	63.9	66.1	64.8
RACE-high (Acc.)	5-shot	49.6	50.8	50.6
DROP (EM)	1-shot	40.0	41.7	33.8
GSM8K (EM)	0-shot	63.4	62.6	62.2
MATH (EM)	4-shot	13.5	14.7	15.2
HumanEval (Pass@1)	0-shot	35.4	45.1	45.7
MBPP (Pass@1)	3-shot	27.8	39.0	46.2
TriviaQA (EM)	5-shot	60.1	59.5	63.3
NaturalQuestions (EM)	零样本	35.2	32.7	35.1
MMLU (准确率)	零样本	50.0	49.7	47.2
Winogrande 数据集 (准确率)	零样本	65.1	68.4	69.0
CLUEWSC (EM)	5-shot	48.4	66.2	68.2
CEval (准确率)	0-shot	35.1	44.7	40.0
CMMLU (准确率)	0-shot	36.9	51.2	49.3

表 5 | 对 LLaMA2 SFT 70亿、DeepSeek Chat 70亿 和 DeepSeekMoE Chat 16B 的比较, 这三个模型均在相同的 SFT 数据上进行了微调。与两款70亿稠密模型相比, DeepSeekMoE Chat 16B 仅使用40%的计算, 仍在大多数基准上获得相当或更好的性能。

6.2. 评估

基线方法。 为验证对齐后的 DeepSeekMoE160亿 的潜力, 我们对 LLaMA2 70亿、DeepSeek 70亿 和 DeepSeekMoE 160 亿 进行有监督微调; 为保证公平性, 我们完全使用相同的微调数据。相应地, 我们构建了三个聊天模型, 包括 LLaMA2 SFT 70亿³, DeepSeek Chat 70亿, 以及 DeepSeek MoE Chat 160亿。随后, 我们将 DeepSeekMoE Chat 160亿 与另外两个稠密聊天模型 (其 FLOPs 约为 DeepSeekMoE Chat 160亿的 2.5 倍) 在广泛的下游任务上进行比较。

³我们使用 LLaMA2 SFT 以区别于官方的 LLaMA2 Chat (Touvron 等, 2023b) 模型。

结果。评测结果见表5。我们的关键观察包括：（1）在仅消耗近40%的计算的情况下，DeepSeekMoE Chat 16B 在语言理解与推理（PIQA、ARC、BBH）、机器阅读理解（RACE）、数学（GSM8K、MATH）以及知识密集型任务（TriviaQA、NaturalQuestions）上取得了与 70 亿稠密模型相当的性能。（2）在代码生成任务上，DeepSeekMoE Chat 16B 显著优于 LLaMA2 SFT 70 亿，并在 HumanEval 和 MBPP 上表现出显著提升。此外，它也超过了 DeepSeek Chat 70 亿。（3）在包含 MMLU、CEval 和 CMMLU 的多项选择问答基准上，DeepSeekMoE Chat 16B 仍然落后于 DeepSeek Chat 70 亿，这与基础模型的观察结果（第 5.2.1 节）一致。然而，值得注意的是，经过监督式微调后，DeepSeekMoE 16B 与 DeepSeek 70 亿之间的性能差距缩小了。（4）得益于在双语语料库上的预训练，DeepSeekMoE Chat 16B 在所有中文基准上显著优于 LLaMA2 SFT 70 亿。这些结果表明 DeepSeekMoE 16B 在中文和英文两种语言上的能力较为均衡，提升了其在多样化场景中的通用性和适用性。总之，针对聊天模型的评测凸显了 DeepSeekMoE 16B 在对齐方面受益的潜力，并验证了其在仅使用约40%的计算情况下仍能达到与稠密模型相当性能的一贯优势。

7. DeepSeekMoE145B 进行中

受 DeepSeekMoE 16B 杰出性能的鼓舞，我们进一步开展初步尝试，将 DeepSeekMoE 扩展到 145B。在这项初步研究中，DeepSeekMoE 145B 在 2450 亿 Token 上进行训练，但已持续表现出相较 GShard 架构的优势，并显示出有望匹敌或超越 DeepSeek 67B（稠密）的性能。此外，在完成 DeepSeekMoE 145B 的最终版本与全量训练后，我们也计划将其公开发布。

7.1. 实验设置

训练数据与分词。对于 DeepSeekMoE 145B，我们使用与 DeepSeekMoE 16B 完全相同的训练语料与分词器，唯一的区别是出于初步研究目的，DeepSeekMoE 145B 在 2450 亿 Token 上进行训练。

模型设置。对于 DeepSeekMoE 145B，我们将 Transformer 层数设为 62，隐藏维度设为 4096。我们采用多头注意机制，总计 32 个注意力头，其中每个头的维度为 128。关于初始化，所有可学习参数均以标准差 0.006 随机初始化。与 DeepSeekMoE 16B 相同，除第一层外，我们将所有前馈网络替换为 MoE 层。每个 MoE 层由 4 个共享专家和 128 个已路由专家组成，其中每个专家的规模为标准前馈网络的 0.125 倍。每个标记将被路由到这 4 个共享专家以及 128 个已路由专家中的 12 个。在该配置下，DeepSeekMoE 145 的总参数约为 1446 亿，激活参数数量约为 222 亿。

训练设置。我们采用 AdamW 优化器（Loshchilov and Hutter, 2019 年），超参数设置为 $\beta_1 = 0.9$ 、 $\beta_2 = 0.95$ ，以及权重_衰减 = 0.1。在 DeepSeekMoE 145B 的初步研究中，我们采用预热-恒定学习率调度器。起始阶段，学习率在最初的 2K 步内从 0 线性增加到最大值。

随后，学习率在剩余的训练过程中保持不变。DeepSeekMoE 145B 的最大学习率设为 3.0×10^{-4} ，梯度裁剪范数设为 1.0。批大小设为 4.5K，在最大序列长度为 4K 的情况下，每个训练批次包含 18M Token。我们对 DeepSeekMoE 145B 训练 13,000 步，累计 245B 训练 Token。此外，我们在训练期间不使用 Dropout（随机失活）。我们利用流水线并行将模型的不同层部署到不同设备上，并且对于每一层，所有已路由的专家将均匀部署在 4 台设备上（即专家并行与数据并行结合）。由于我们为 DeepSeekMoE 145B 采用专家并行，需要考虑设备级负载均衡以减少计算瓶颈。对此，我们将设备级平衡因子设为 0.05，以鼓励跨设备的计算均衡。此外，我们仍将专家级平衡因子设为 0.003，以防止路由坍塌。

评测基准。我们在与 DeepSeekMoE 16B 完全相同的内部基准上评估 DeepSeekMoE 145B（参见第 5.1.3 节）。

7.2. 评测

基线。除了 DeepSeekMoE 145B 之外，我们还考虑了另外三种模型用于比较。**DeepSeek 67B (稠密)** 是一个总参数为 67.4B 的稠密模型（有关模型和训练细节，参见 DeepSeek-AI（2024 年））。**GShard 137B** 与 DeepSeekMoE 145B 拥有相同的隐藏维度和层数，但采用 GShard 架构。请注意，DeepSeekMoE 145B 为了计算效率，将每个专家中的中间表示的隐藏维度对齐为 64 的倍数，因此其模型规模比 GShard 137B 大 6%。**DeepSeekMoE 142B (半激活)** 与 DeepSeekMoE 145B 的架构相似，但它仅包含 2 个共享专家，并且在 128 个已路由专家中只有 6 个被激活。值得注意的是，包括 DeepSeekMoE 145B 在内的所有对比模型共享相同的训练语料。此外，对比中的所有 MoE 模型均从头开始训练，并共享相同的训练超参数。

结果。根据表 6 所示的评估结果，我们有以下观察：（1）尽管总体参数和计算可比，DeepSeekMoE 1450 亿显著优于 GShard 1370 亿，再次凸显了 DeepSeekMoE 架构的优势。（2）整体而言，仅用 28.5% 的计算，DeepSeekMoE 1450 亿取得了与 DeepSeek 670 亿（稠密）相当的性能。与 DeepSeekMoE 160 亿的发现一致，DeepSeekMoE 1450 亿在语言建模和知识密集型任务上展现出显著优势，但在多项选择任务上存在局限性。（3）在更大的缩放下，DeepSeekMoE 1420 亿（Half Activated）的性能与 DeepSeekMoE 1450 亿相比并未落后太多。此外，尽管仅有一半被激活的专家参数，DeepSeekMoE 1420 亿（Half Activated）在仅用 18.2% 的计算的情况下，仍能达到 DeepSeek 670 亿（稠密）的性能。它也优于 GShard 1370 亿，这与第 4.5 节的结论一致。

8. 相关工作

专家混合（MoE）技术最早由 Jacobs 等（1991）；Jordan 和 Jacobs（1994）提出，用独立的专家模块处理不同样本。Shazeer 等（2017）将 MoE 引入语言模型训练，并构建了大规模的基于 LSTM 的（Hochreiter 和 Schmidhuber, 1997）MoE 模型。随着 Transformer 架构成为最流行的架构

指标	# 示例数	DeepSeek 670亿 (稠密)	GShard 137B	DeepSeekMoE 145B	DeepSeekMoE 1420亿 (半激活)
# 总参数量	N/A	674亿	1365亿	1446亿	1423亿
# 激活参数	N/A	674亿	216亿	222亿	122亿
相对专家规模	N/A	N/A	1	0.125	0.125
专家数	N/A	N/A	0 + 16	4 + 128	2 + 128
已激活专家数	N/A	N/A	0 + 2	4 + 12	2 + 6
每 4K Token 的 FLOPs	N/A	2057.5T	572.7T	585.6T	374.6T
# 训练 Token	N/A	245B	245B	245B	245B
Pile (损失)	N/A	1.905	1.961	1.876	1.888
HellaSwag (准确率)	零样本	74.8	72.0	75.8	74.9
PIQA (准确率)	零样本	79.8	77.6	80.7	80.2
ARC-easy (准确率)	零样本	69.0	64.0	69.7	67.9
ARC-challenge (准确率)	零样本	50.4	45.8	48.8	49.0
RACE-middle (准确率)	5-shot	63.2	59.2	62.1	59.5
RACE-high (准确率)	5-shot	46.9	43.5	45.5	42.6
DROP (EM)	1-shot	27.5	21.6	27.8	28.9
GSM8K (EM)	8-shot	11.8	6.4	12.2	13.8
MATH (EM)	4-shot	2.1	1.6	3.1	2.8
HumanEval (Pass@1)	0-shot	23.8	17.7	19.5	23.2
MBPP (Pass@1)	3-shot	33.6	27.6	33.2	32.0
TriviaQA (EM)	5-shot	57.2	52.5	61.1	59.8
NaturalQuestions (EM)	5-shot	22.6	19.0	25.0	23.5
MMLU (Acc.)	5-shot	45.1	26.3	39.4	37.5
Winogrande 数据集 (准确率)	0-shot	70.7	67.6	71.9	70.8
CLUEWSC (EM)	5-shot	69.1	65.7	71.9	72.6
CEval (准确率)	5-shot	40.3	26.2	37.1	32.8
CMMLU (准确率)	5-shot	40.6	25.4	35.9	31.9
CHID (准确率)	0-shot	88.5	86.9	90.3	88.3

表 6 | DeepSeek 67B (稠密) 与 MoE 模型在总参数约为 140B 的规模下的比较。在“# Experts”和“# Activated Experts”两行中， $a + b$ 表示 a 共享专家和 b 已路由专家。**粗体** 字体表示除最后一列外的最佳或接近最佳性能。DeepSeekMoE 145B，甚至仅有一半激活专家参数的 DeepSeekMoE 142B (半激活)，都以显著优势优于 GShard 137B。此外，仅用 28.5% 的计算，DeepSeekMoE 145B 即可取得与 DeepSeek 67B 可比的性能。

针对自然语言处理 (NLP)，许多尝试将 Transformer 架构中的前馈网络扩展为 MoE 层，以构建 MoE 语言模型。GShard (Lepikhin 等, 2021 年) 和 Switch Transformer (Fedus 等, 2021 年) 是先驱，它们采用可学习的 top-2 或 top-1 路由策略，将 MoE 语言模型扩展到极大规模。Hash Layer (Roller 等, 2021 年) 和 StableMoE (Dai 等, 2022b) 使用固定路由策略，以获得更稳定的路由和训练。Zhou 等 (2022 年) 提出一种 expert-choice 路由策略，其中每个标记可以被分配给不同数量的专家。Zoph (2022 年) 关注 MoE 模型中的训练不稳定性与微调困难，

并提出 ST-MoE 来克服这些挑战。除了对 MoE 架构和训练策略的研究，近年来还出现了大量基于现有 MoE 架构的大规模语言或多模态模型（Du 等，2022年；Lin 等，2021年；Ren 等，2023年；Xue 等，2023年）。总体而言，以往的大多数 MoE 模型都基于常规的 top-1或 top-2路由策略，在提升专家专精方面仍留有很大空间。对此，我们的 DeepSeekMoE 架构旨在将专家专精提升到极致。

9. 结论

在本文中，我们介绍了用于专家混合语言模型的 DeepSeekMoE 架构，以实现终极专家专门化为目标函数。通过细粒度的专家分割与共享专家隔离，DeepSeekMoE 相较于主流的专家混合架构在专家专门化程度与性能上均显著提升。我们从仅有 20亿 参数的适度规模出发，验证了 DeepSeekMoE 的优势，表明其有能力逼近 MoE 模型的性能上界。此外，我们提供了实证证据显示，DeepSeekMoE 的专家专门化水平高于 GShard。

将总参数量扩展到 160亿 后，我们在 2T 个标记上训练了 DeepSeekMoE 16B，并展示了其与 DeepSeek 70亿 和 LLaMA2 70亿 相当的出色性能，而所需计算仅约为 40%。此外，我们进行了用于对齐的监督微调，在 DeepSeekMoE 16B 基础上构建了一个专家混合聊天模型，进一步体现其适应性与通用性。进一步地，我们对将 DeepSeek- MoE 扩展到 1450亿 参数进行了初步探索。我们发现，DeepSeekMoE 145B 仍然相比 GShard 架构保持显著优势，并以仅 28.5%（甚至可能是 18.2%）的计算展现出与 DeepSeek 670亿 相当的性能。

出于研究目的，我们向公众发布 DeepSeekMoE 16B 的模型检查点，可在具有 40GB 内存的单张GPU 上部署。我们期望这项工作能为学术界和工业界提供有价值的洞见，并推动大规模语言模型的加速发展。

参考文献

E. Almazrouei, H. Alobeidli, A. Alshamsi, A. Cappelli, R. Cojocaru, M. Debbah, E. Goffinet, D. Heslow, J. Launay, Q. Malartic, B. Noune, B. Pannier, and G. Penedo. Falcon-40B: 一款具有当前最先进水平性能的开放大规模语言模型, 2023年. M. Artetxe, S. Bhosale, N. Goyal, T. Mihaylov, M. Ott, S. Shleifer, X. V. Lin, J. Du, S. Iyer, R. Pasunuru, G. Anantharaman, X. Li, S. Chen, H. Akin, M. Baines, L. Martin, X. Zhou, P. S. Koura, B. O'Horo, J. Wang, L. Zettlemoyer, M. T. Diab, Z. Kozareva, and V. Stoyanov. 基于专家混合的高效大规模语言建模. In Y. Goldberg, Z. Kozareva, and Y. Zhang, editors, *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing, EMNLP 2022, Abu Dhabi, United Arab Emirates, December 7-11, 2022*, pages 11699–11732. Association for Computational Linguistics, 2022年. 数字对象唯一标识符: 10.18653/V1/2022 .EMNLP-MAIN.804. URL <https://doi.org/10.18653/v1/2022.emnlp-main.804>. J. Austin, A. Odena, M. Nye, M. Bosma, H. Michalewski, D. Dohan, E. Jiang, C. Cai, M. Terry, Q. Le, et al. 使用大规模语言模型进行程序综合. arXiv 预印本 arXiv:2108.07732, 2021年.

- S. Biderman, H. Schoelkopf, Q. G. Anthony, H. Bradley, K. O'Brien, E. Hallahan, M. A. Khan, S. Purohit, U. S. Prashanth, E. Raff, A. Skowron, L. Sutawika, and O. van der Wal. Pythia: A suite for analyzing large language models across training and scaling. In A. Krause, E. Brunskill, K. Cho, B. Engelhardt, S. Sabato, and J. Scarlett, editors, *International Conference on Machine Learning, ICML 2023, 23-29 July 2023, Honolulu, Hawaii, USA*, volume 202 of *Proceedings of Machine Learning Research*, pages 2397–2430. PMLR, 2023. URL <https://proceedings.mlr.press/v202/biderman23a.html>.
- Y. Bisk, R. Zellers, R. L. Bras, J. Gao, and Y. Choi. PIQA: reasoning about physical commonsense in natural language. In *The Thirty-Fourth AAAI Conference on Artificial Intelligence, AAAI 2020, The Thirty-Second Innovative Applications of Artificial Intelligence Conference, IAAI 2020, The Tenth AAAI Symposium on Educational Advances in Artificial Intelligence, EAAI 2020, New York, NY, USA, February 7-12, 2020*, pages 7432–7439. AAAI Press, 2020. doi: 10.1609/aaai.v34i05.6239. URL <https://doi.org/10.1609/aaai.v34i05.6239>.
- S. Black, L. Gao, P. Wang, C. Leahy, and S. Biderman. GPT-Neo: Large Scale Autoregressive Language Modeling with Mesh-Tensorflow, Mar. 2021. URL <https://doi.org/10.5281/zenodo.5297715>. If you use this misc, please cite it using these metadata.
- T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei. Language models are few-shot learners. In *Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020*, 2020. URL <https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>.
- M. Chen, J. Tworek, H. Jun, Q. Yuan, H. P. de Oliveira Pinto, J. Kaplan, H. Edwards, Y. Burda, N. Joseph, G. Brockman, A. Ray, R. Puri, G. Krueger, M. Petrov, H. Khlaaf, G. Sastry, P. Mishkin, B. Chan, S. Gray, N. Ryder, M. Pavlov, A. Power, L. Kaiser, M. Bavarian, C. Winter, P. Tillet, F. P. Such, D. Cummings, M. Plappert, F. Chantzis, E. Barnes, A. Herbert-Voss, W. H. Guss, A. Nichol, A. Paino, N. Tezak, J. Tang, I. Babuschkin, S. Balaji, S. Jain, W. Saunders, C. Hesse, A. N. Carr, J. Leike, J. Achiam, V. Misra, E. Morikawa, A. Radford, M. Knight, M. Brundage, M. Murati, K. Mayer, P. Welinder, B. McGrew, D. Amodei, S. McCandlish, I. Sutskever, and W. Zaremba. Evaluating large language models trained on code. *CoRR*, abs/2107.03374, 2021. URL <https://arxiv.org/abs/2107.03374>.
- P. Clark, I. Cowhey, O. Etzioni, T. Khot, A. Sabharwal, C. Schoenick, and O. Tafjord. Think you have solved question answering? try arc, the AI2 reasoning challenge. *CoRR*, abs/1803.05457, 2018. URL <http://arxiv.org/abs/1803.05457>.
- K. Cobbe, V. Kosaraju, M. Bavarian, M. Chen, H. Jun, L. Kaiser, M. Plappert, J. Tworek, J. Hilton, R. Nakano, et al. Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*, 2021.
- D. Dai, L. Dong, Y. Hao, Z. Sui, B. Chang, and F. Wei. Knowledge neurons in pretrained transformers. In S. Muresan, P. Nakov, and A. Villavicencio, editors, *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, ACL 2022, Dublin, Ireland, May 22-27, 2022, pages 8493–8502. Association for Computational Linguistics, 2022a. doi: 10.18653/V1/2022.ACL-LONG.581. URL <https://doi.org/10.18653/v1/2022.acl-long.581>.

- D. Dai, L. Dong, S. Ma, B. Zheng, Z. Sui, B. Chang, and F. Wei. Stablemoe: Stable routing strategy for mixture of experts. In S. Muresan, P. Nakov, and A. Villavicencio, editors, Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2022, Dublin, Ireland, May 22-27, 2022, pages 7085–7095. Association for Computational Linguistics, 2022b. doi: 10.18653/V1/2022.ACL-LONG.489. URL <https://doi.org/10.18653/v1/2022.acl-long.489>.
- DeepSeek-AI. Deepseek llm: Scaling open-source language models with longtermism. arXiv preprint arXiv:2401.02954, 2024.
- N. Du, Y. Huang, A. M. Dai, S. Tong, D. Lepikhin, Y. Xu, M. Krikun, Y. Zhou, A. W. Yu, O. Firat, B. Zoph, L. Fedus, M. P. Bosma, Z. Zhou, T. Wang, Y. E. Wang, K. Webster, M. Pellat, K. Robinson, K. S. Meier-Hellstern, T. Duke, L. Dixon, K. Zhang, Q. V. Le, Y. Wu, Z. Chen, and C. Cui. Glam: Efficient scaling of language models with mixture-of-experts. In International Conference on Machine Learning, ICML 2022, 17-23 July 2022, Baltimore, Maryland, USA, volume 162 of Proceedings of Machine Learning Research, pages 5547–5569. PMLR, 2022. URL <https://proceedings.mlr.press/v162/du22c.html>.
- D. Dua, Y. Wang, P. Dasigi, G. Stanovsky, S. Singh, and M. Gardner. DROP: A reading comprehension benchmark requiring discrete reasoning over paragraphs. In J. Burstein, C. Doran, and T. Solorio, editors, Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2019, Minneapolis, MN, USA, June 2-7, 2019, Volume 1 (Long and Short Papers), pages 2368–2378. Association for Computational Linguistics, 2019. doi: 10.18653/V1/N19-1246. URL <https://doi.org/10.18653/v1/n19-1246>.
- W. Fedus, B. Zoph, and N. Shazeer. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. CoRR, abs/2101.03961, 2021. URL <https://arxiv.org/abs/2101.03961>.
- L. Gao, S. Biderman, S. Black, L. Golding, T. Hoppe, C. Foster, J. Phang, H. He, A. Thite, N. Nabeshima, et al. The Pile: An 800GB dataset of diverse text for language modeling. arXiv preprint arXiv:2101.00027, 2020.
- X. Geng and H. Liu. Openllama: An open reproduction of llama, May 2023. URL https://github.com/openlm-research/open_llama.
- A. Harlap, D. Narayanan, A. Phanishayee, V. Seshadri, N. R. Devanur, G. R. Ganger, and P. B. Gibbons. Pipedream: Fast and efficient pipeline parallel DNN training. CoRR, abs/1806.03377, 2018. URL <http://arxiv.org/abs/1806.03377>.
- D. Hendrycks, C. Burns, S. Basart, A. Zou, M. Mazeika, D. Song, and J. Steinhardt. Measuring massive multitask language understanding. arXiv preprint arXiv:2009.03300, 2020.
- D. Hendrycks, C. Burns, S. Kadavath, A. Arora, S. Basart, E. Tang, D. Song, and J. Steinhardt. Measuring mathematical problem solving with the math dataset, 2021.
- High-Flyer. Hai-llm: An efficient and lightweight tool for training large models, 2023. URL <https://www.high-flyer.cn/en/blog/hai-llm>.
- S. Hochreiter and J. Schmidhuber. Long short-term memory. Neural Computing, 9(8):1735–1780, 1997. URL <https://doi.org/10.1162/neco.1997.9.8.1735>.

- J. Hoffmann, S. Borgeaud, A. Mensch, E. Buchatskaya, T. Cai, E. Rutherford, D. de Las Casas, L. A. Hendricks, J. Welbl, A. Clark, T. Hennigan, E. Noland, K. Millican, G. van den Driessche, B. Damoc, A. Guy, S. Osindero, K. Simonyan, E. Elsen, J. W. Rae, O. Vinyals, and L. Sifre. Training compute-optimal large language models. *CoRR*, abs/2203.15556, 2022. doi: 10.48550/arXiv.2203.15556. URL <https://doi.org/10.48550/arXiv.2203.15556>.
- Y. Huang, Y. Bai, Z. Zhu, J. Zhang, J. Zhang, T. Su, J. Liu, C. Lv, Y. Zhang, J. Lei, et al. C-Eval: A multi-level multi-discipline chinese evaluation suite for foundation models. *arXiv preprint arXiv:2305.08322*, 2023.
- R. A. Jacobs, M. I. Jordan, S. J. Nowlan, and G. E. Hinton. Adaptive mixtures of local experts. *Neural Computing*, 3(1):79–87, 1991. URL <https://doi.org/10.1162/neco.1991.3.1.79>.
- M. I. Jordan and R. A. Jacobs. Hierarchical mixtures of experts and the EM algorithm. *Neural Computing*, 6(2):181–214, 1994. URL <https://doi.org/10.1162/neco.1994.6.2.181>.
- M. Joshi, E. Choi, D. Weld, and L. Zettlemoyer. triviaqa: A Large Scale Distantly Supervised Challenge Dataset for Reading Comprehension. *arXiv e-prints*, art. arXiv:1705.03551, 2017.
- V. A. Korthikanti, J. Casper, S. Lym, L. McAfee, M. Andersch, M. Shoeybi, and B. Catanzaro. Reducing activation recomputation in large transformer models. *Proceedings of Machine Learning and Systems*, 5, 2023.
- T. Kwiatkowski, J. Palomaki, O. Redfield, M. Collins, A. Parikh, C. Alberti, D. Epstein, I. Polosukhin, M. Kelcey, J. Devlin, K. Lee, K. N. Toutanova, L. Jones, M.-W. Chang, A. Dai, J. Uszkoreit, Q. Le, and S. Petrov. Natural questions: a benchmark for question answering research. *Transactions of the Association of Computational Linguistics*, 2019.
- G. Lai, Q. Xie, H. Liu, Y. Yang, and E. H. Hovy. RACE: large-scale reading comprehension dataset from examinations. In M. Palmer, R. Hwa, and S. Riedel, editors, *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, EMNLP 2017, Copenhagen, Denmark, September 9-11, 2017*, pages 785–794. Association for Computational Linguistics, 2017. doi: 10.18653/V1/D17-1082. URL <https://doi.org/10.18653/v1/d17-1082>.
- D. Lepikhin, H. Lee, Y. Xu, D. Chen, O. Firat, Y. Huang, M. Krikun, N. Shazeer, and Z. Chen. Gshard: Scaling giant models with conditional computation and automatic sharding. In *9th International Conference on Learning Representations, ICLR 2021*. OpenReview.net, 2021. URL <https://openreview.net/forum?id=qrwe7XHTmYb>.
- H. Li, Y. Zhang, F. Koto, Y. Yang, H. Zhao, Y. Gong, N. Duan, and T. Baldwin. CMMLU: Measuring massive multitask language understanding in Chinese. *arXiv preprint arXiv:2306.09212*, 2023.
- J. Lin, R. Men, A. Yang, C. Zhou, M. Ding, Y. Zhang, P. Wang, A. Wang, L. Jiang, X. Jia, J. Zhang, J. Zhang, X. Zou, Z. Li, X. Deng, J. Liu, J. Xue, H. Zhou, J. Ma, J. Yu, Y. Li, W. Lin, J. Zhou, J. Tang, and H. Yang. M6: A chinese multimodal pretrainer. *CoRR*, abs/2103.00823, 2021. URL <https://arxiv.org/abs/2103.00823>.
- S. Lin, J. Hilton, and O. Evans. Truthfulqa: Measuring how models mimic human falsehoods. In S. Muresan, P. Nakov, and A. Villavicencio, editors, *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2022, Dublin*,

- Ireland, May 22-27, 2022, pages 3214–3252. Association for Computational Linguistics, 2022. doi: 10.18653/V1/2022.ACL-LONG.229. URL <https://doi.org/10.18653/v1/2022.acl-long.229>.
- I. Loshchilov and F. Hutter. Decoupled weight decay regularization. In 7th International Conference on Learning Representations, ICLR 2019, New Orleans, LA, USA, May 6-9, 2019. OpenReview.net, 2019. URL <https://openreview.net/forum?id=Bkg6RiCqY7>.
- D. Narayanan, M. Shoeybi, J. Casper, P. LeGresley, M. Patwary, V. Korthikanti, D. Vainbrand, P. Kashinkunti, J. Bernauer, B. Catanzaro, et al. Efficient large-scale language model training on gpu clusters using megatron-lm. In Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis, pages 1–15, 2021.
- OpenAI. GPT-4 technical report. CoRR, abs/2303.08774, 2023. doi: 10.48550/arXiv.2303.08774. URL <https://doi.org/10.48550/arXiv.2303.08774>.
- S. Rajbhandari, J. Rasley, O. Ruwase, and Y. He. Zero: memory optimizations toward training trillion parameter models. In C. Cuicchi, I. Qualters, and W. T. Kramer, editors, Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis, SC 2020, Virtual Event / Atlanta, Georgia, USA, November 9-19, 2020, page 20. IEEE/ACM, 2020. doi: 10.1109/SC41405.2020.00024. URL <https://doi.org/10.1109/SC41405.2020.00024>.
- S. Rajbhandari, C. Li, Z. Yao, M. Zhang, R. Y. Aminabadi, A. A. Awan, J. Rasley, and Y. He. Deepspeed-moe: Advancing mixture-of-experts inference and training to power next-generation AI scale. In K. Chaudhuri, S. Jegelka, L. Song, C. Szepesvári, G. Niu, and S. Sabato, editors, International Conference on Machine Learning, ICML 2022, 17-23 July 2022, Baltimore, Maryland, USA, volume 162 of Proceedings of Machine Learning Research, pages 18332–18346. PMLR, 2022. URL <https://proceedings.mlr.press/v162/rajbhandari22a.html>.
- X. Ren, P. Zhou, X. Meng, X. Huang, Y. Wang, W. Wang, P. Li, X. Zhang, A. Podolskiy, G. Arshinov, A. Bout, I. Piontkovskaya, J. Wei, X. Jiang, T. Su, Q. Liu, and J. Yao. Pangu- Σ : Towards trillion parameter language model with sparse heterogeneous computing. CoRR, abs/2303.10845, 2023. URL <https://doi.org/10.48550/arXiv.2303.10845>.
- S. Roller, S. Sukhbaatar, A. Szlam, and J. Weston. Hash layers for large sparse models. CoRR, abs/2106.04426, 2021. URL <https://arxiv.org/abs/2106.04426>.
- K. Sakaguchi, R. L. Bras, C. Bhagavatula, and Y. Choi. Winogrande: An adversarial winograd schema challenge at scale, 2019.
- T. L. Scao, A. Fan, C. Akiki, E. Pavlick, S. Ilıc, D. Hesslow, R. Castagné, A. S. Luccioni, F. Yvon, M. Gallé, J. Tow, A. M. Rush, S. Biderman, A. Webson, P. S. Ammanamanchi, T. Wang, B. Sagot, N. Muennighoff, A. V. del Moral, O. Ruwase, R. Bawden, S. Bekman, A. McMillan-Major, I. Beltagy, H. Nguyen, L. Saulnier, S. Tan, P. O. Suarez, V. Sanh, H. Laurençon, Y. Jernite, J. Launay, M. Mitchell, C. Raffel, A. Gokaslan, A. Simhi, A. Soroa, A. F. Aji, A. Alfassy, A. Rogers, A. K. Nitzav, C. Xu, C. Mou, C. Emezue, C. Klamm, C. Leong, D. van Strien, D. I. Adelani, and et al. BLOOM: A 176b-parameter open-access multilingual language model. CoRR, abs/2211.05100, 2022. doi: 10.48550/ARXIV.2211.05100. URL <https://doi.org/10.48550/arXiv.2211.05100>.

- R. Sennrich, B. Haddow, and A. Birch. Neural machine translation of rare words with subword units. In Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics, ACL 2016, August 7-12, 2016, Berlin, Germany, Volume 1: Long Papers. The Association for Computer Linguistics, 2016. doi: 10.18653/V1/P16-1162. URL <https://doi.org/10.18653/v1/p16-1162>.
- N. Shazeer. Fast transformer decoding: One write-head is all you need. CoRR, abs/1911.02150, 2019. URL <http://arxiv.org/abs/1911.02150>.
- N. Shazeer, A. Mirhoseini, K. Maziarz, A. Davis, Q. V. Le, G. E. Hinton, and J. Dean. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. In 5th International Conference on Learning Representations, ICLR 2017. OpenReview.net, 2017. URL <https://openreview.net/forum?id=B1ckMDqlg>.
- S. Shen, L. Hou, Y. Zhou, N. Du, S. Longpre, J. Wei, H. W. Chung, B. Zoph, W. Fedus, X. Chen, T. Vu, Y. Wu, W. Chen, A. Webson, Y. Li, V. Zhao, H. Yu, K. Keutzer, T. Darrell, and D. Zhou. Flan-moe: Scaling instruction-finetuned language models with sparse mixture of experts. CoRR, abs/2305.14705, 2023. doi: 10.48550/ARXIV.2305.14705. URL <https://doi.org/10.48550/arXiv.2305.14705>.
- M. Shoenberger, M. Patwary, R. Puri, P. LeGresley, J. Casper, and B. Catanzaro. Megatron-lm: Training multi-billion parameter language models using model parallelism. arXiv preprint arXiv:1909.08053, 2019.
- M. Suzgun, N. Scales, N. Schärli, S. Gehrmann, Y. Tay, H. W. Chung, A. Chowdhery, Q. V. Le, E. H. Chi, D. Zhou, et al. Challenging big-bench tasks and whether chain-of-thought can solve them. arXiv preprint arXiv:2210.09261, 2022.
- P. Tillet, H. T. Kung, and D. Cox. Triton: An intermediate language and compiler for tiled neural network computations. In Proceedings of the 3rd ACM SIGPLAN International Workshop on Machine Learning and Programming Languages, MAPL 2019, page 10–19, New York, NY, USA, 2019. Association for Computing Machinery. ISBN 9781450367196. doi: 10.1145/3315508.3329973. URL <https://doi.org/10.1145/3315508.3329973>.
- Together-AI. Redpajama-data: An open source recipe to reproduce llama training dataset, April 2023. URL <https://github.com/togethercomputer/RedPajama-Data>.
- H. Touvron, T. Lavril, G. Izacard, X. Martinet, M. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar, A. Rodriguez, A. Joulin, E. Grave, and G. Lample. Llama: Open and efficient foundation language models. CoRR, abs/2302.13971, 2023a. doi: 10.48550/arXiv.2302.13971. URL <https://doi.org/10.48550/arXiv.2302.13971>.
- H. Touvron, L. Martin, K. Stone, P. Albert, A. Almahairi, Y. Babaei, N. Bashlykov, S. Batra, P. Bhargava, S. Bhosale, D. Bikel, L. Blecher, C. Canton-Ferrer, M. Chen, G. Cucurull, D. Esiobu, J. Fernandes, J. Fu, W. Fu, B. Fuller, C. Gao, V. Goswami, N. Goyal, A. Hartshorn, S. Hosseini, R. Hou, H. Inan, M. Kardas, V. Kerkez, M. Khabsa, I. Kloumann, A. Korenev, P. S. Koura, M. Lachaux, T. Lavril, J. Lee, D. Liskovich, Y. Lu, Y. Mao, X. Martinet, T. Mihaylov, P. Mishra, I. Molybog, Y. Nie, A. Poulton, J. Reizenstein, R. Rungta, K. Saladi, A. Schelten, R. Silva, E. M. Smith, R. Subramanian, X. E. Tan, B. Tang, R. Taylor, A. Williams, J. X. Kuan, P. Xu, Z. Yan, I. Zarov, Y. Zhang, A. Fan, M. Kambadur, S. Narang, A. Rodriguez, R. Stojnic, S. Edunov, and T. Scialom. Llama 2: Open foundation and fine-tuned chat models. CoRR, abs/2307.09288, 2023b. doi: 10.48550/arXiv.2307.09288. URL <https://doi.org/10.48550/arXiv.2307.09288>.

- A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017*, pages 5998–6008, 2017. URL <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>.
- B. Wang and A. Komatsuzaki. GPT-J-6B: A 6 Billion Parameter Autoregressive Language Model. <https://github.com/kingoflolz/mesh-transformer-jax>, May 2021.
- L. Xu, H. Hu, X. Zhang, L. Li, C. Cao, Y. Li, Y. Xu, K. Sun, D. Yu, C. Yu, Y. Tian, Q. Dong, W. Liu, B. Shi, Y. Cui, J. Li, J. Zeng, R. Wang, W. Xie, Y. Li, Y. Patterson, Z. Tian, Y. Zhang, H. Zhou, S. Liu, Z. Zhao, Q. Zhao, C. Yue, X. Zhang, Z. Yang, K. Richardson, and Z. Lan. CLUE: A chinese language understanding evaluation benchmark. In D. Scott, N. Bel, and C. Zong, editors, *Proceedings of the 28th International Conference on Computational Linguistics, COLING 2020, Barcelona, Spain (Online), December 8-13, 2020*, pages 4762–4772. International Committee on Computational Linguistics, 2020. doi: 10.18653/V1/2020.COLING-MAIN.419. URL <https://doi.org/10.18653/v1/2020.coling-main.419>.
- F. Xue, Z. Zheng, Y. Fu, J. Ni, Z. Zheng, W. Zhou, and Y. You. Openmoe: Open mixture-of-experts language models. <https://github.com/XueFuzhao/OpenMoE>, 2023.
- R. Zellers, A. Holtzman, Y. Bisk, A. Farhadi, and Y. Choi. HellaSwag: Can a machine really finish your sentence? In A. Korhonen, D. R. Traum, and L. Màrquez, editors, *Proceedings of the 57th Conference of the Association for Computational Linguistics, ACL 2019, Florence, Italy, July 28- August 2, 2019, Volume 1: Long Papers*, pages 4791–4800. Association for Computational Linguistics, 2019. doi: 10.18653/v1/p19-1472. URL <https://doi.org/10.18653/v1/p19-1472>.
- S. Zhang, S. Roller, N. Goyal, M. Artetxe, M. Chen, S. Chen, C. Dewan, M. Diab, X. Li, X. V. Lin, T. Mihaylov, M. Ott, S. Shleifer, K. Shuster, D. Simig, P. S. Koura, A. Sridhar, T. Wang, and L. Zettlemoyer. Opt: Open pre-trained transformer language models, 2022.
- C. Zheng, M. Huang, and A. Sun. Chid: A large-scale chinese idiom dataset for cloze test. In A. Korhonen, D. R. Traum, and L. Màrquez, editors, *Proceedings of the 57th Conference of the Association for Computational Linguistics, ACL 2019, Florence, Italy, July 28- August 2, 2019, Volume 1: Long Papers*, pages 778–787. Association for Computational Linguistics, 2019. doi: 10.18653/V1/P19-1075. URL <https://doi.org/10.18653/v1/p19-1075>.
- Y. Zhou, T. Lei, H. Liu, N. Du, Y. Huang, V. Zhao, A. M. Dai, Z. Chen, Q. V. Le, and J. Laudon. Mixture-of-experts with expert choice routing. In *NeurIPS*, 2022. URL http://papers.nips.cc/paper_files/paper/2022/hash/2f00ecd787b432c1d36f3de9800728eb-Abstract-Conference.html.
- B. Zoph. Designing effective sparse expert models. In *IEEE International Parallel and Distributed Processing Symposium, IPDPS Workshops 2022, Lyon, France, May 30 - June 3, 2022*, page 1044. IEEE, 2022. URL <https://doi.org/10.1109/IPDPSW55747.2022.00171>.

Appendices

A. Overview of Hyper-Parameters

We present the overview of hyper-parameters for DeepSeekMoE across various sizes in Table 7.

# Params	# Layers	Hidden Size	# Attn Heads	# Shared Experts	# Routed Experts	Relative Expert Size	Sequence Length	Batch Size (Sequence)	Learning Rate
2.0B	9	1280	10	1	63 (7 activated)	0.25	2048	2048	1.08e-3
16.4B	28	2048	16	2	64 (6 activated)	0.25	4096	4608	4.2e-4
144.6B	62	4096	32	4	128 (12 activated)	0.125	4096	4608	3.0e-4

Table 7 | Overview of hyper-parameters for DeepSeekMoE across various sizes. The relative expert size is in comparison to a standard FFN.

B. Comparing DeepSeekMoE with Larger Models

Comparisons among DeepSeekMoE, GShard×1.2, and GShard×1.5 are shown in Table 8. Comparisons among DeepSeekMoE, Dense×4, and Dense×16 are shown in Table 9.

Metric	# Shot	GShard×1.2	GShard×1.5	DeepSeekMoE
Relative Expert Size	N/A	1.2	1.5	0.25
# Experts	N/A	0 + 16	0 + 16	1 + 63
# Activated Experts	N/A	0 + 2	0 + 2	1 + 7
# Total Expert Params	N/A	2.3B	2.8B	1.9B
# Activated Expert Params	N/A	0.28B	0.35B	0.24B
# Training Tokens	N/A	100B	100B	100B
Pile (Loss)	N/A	1.824	1.808	1.808
HellaSwag (Acc.)	0-shot	53.7	54.4	54.8
PIQA (Acc.)	0-shot	71.8	71.1	72.3
ARC-easy (Acc.)	0-shot	46.8	47.3	49.4
ARC-challenge (Acc.)	0-shot	31.7	34.1	34.3
RACE-middle (Acc.)	5-shot	43.7	46.4	44.0
RACE-high (Acc.)	5-shot	31.9	32.4	31.7
HumanEval (Pass@1)	0-shot	3.7	3.0	4.9
MBPP (Pass@1)	3-shot	2.4	2.6	2.2
TriviaQA (EM)	5-shot	15.2	15.7	16.6
NaturalQuestions (EM)	5-shot	4.5	4.7	5.7

Table 8 | Comparison between DeepSeekMoE and larger GShard models.

At a larger scale of 13B total parameters, we also compare DeepSeekMoE with GShard×1.2 and GShard×1.5, and show results in Table 10. At a larger scale, DeepSeekMoE even outperforms GShard×1.5 distinctly.

Metric	# Shot	Dense×4	Dense×16	DeepSeekMoE
Relative Expert Size	N/A	1	1	0.25
# Experts	N/A	4 + 0	16 + 0	1 + 63
# Activated Experts	N/A	4 + 0	16 + 0	1 + 7
# Total Expert Params	N/A	0.47B	1.89B	1.89B
# Activated Expert Params	N/A	0.47B	1.89B	0.24B
# Training Tokens	N/A	100B	100B	100B
Pile (Loss)	N/A	1.908	1.806	1.808
HellaSwag (Acc.)	0-shot	47.6	55.1	54.8
PIQA (Acc.)	0-shot	70.0	71.9	72.3
ARC-easy (Acc.)	0-shot	43.9	51.9	49.4
ARC-challenge (Acc.)	0-shot	30.5	33.8	34.3
RACE-middle (Acc.)	5-shot	42.4	46.3	44.0
RACE-high (Acc.)	5-shot	30.7	33.0	31.7
HumanEval (Pass@1)	0-shot	1.8	4.3	4.9
MBPP (Pass@1)	3-shot	0.2	2.2	2.2
TriviaQA (EM)	5-shot	9.9	16.5	16.6
NaturalQuestions (EM)	5-shot	3.0	6.3	5.7

Table 9 | Comparison between DeepSeekMoE and larger dense baselines.

Metric	# Shot	GShard×1.2	GShard×1.5	DeepSeekMoE
Relative Expert Size	N/A	1.2	1.5	0.25
# Experts	N/A	0 + 16	0 + 16	1 + 63
# Activated Experts	N/A	0 + 2	0 + 2	1 + 7
# Total Expert Params	N/A	15.9B	19.8B	13.3B
# Activated Expert Params	N/A	2.37B	2.82B	2.05B
# Training Tokens	N/A	100B	100B	100B
HellaSwag (Acc.)	0-shot	66.6	67.7	69.1
PIQA (Acc.)	0-shot	75.6	76.0	75.7
ARC-easy (Acc.)	0-shot	56.8	56.8	58.8
ARC-challenge (Acc.)	0-shot	39.9	37.6	38.5
RACE-middle (Acc.)	5-shot	51.6	50.6	52.4
RACE-high (Acc.)	5-shot	37.4	36.3	38.5
HumanEval (Pass@1)	0-shot	6.1	6.1	9.8
MBPP (Pass@1)	3-shot	7.0	11.6	10.6
TriviaQA (EM)	5-shot	36.5	36.7	38.2
NaturalQuestions (EM)	5-shot	12.6	12.1	13.7

Table 10 | Comparison between DeepSeekMoE and larger GShard models at a larger scale.

C. Training Benchmark Curves of DeepSeekMoE 16B

We present the benchmark curves during training of DeepSeekMoE 16B and DeepSeek 7B (Dense) in Figure 7 for reference.




Figure 7 | Benchmark curves during training of DeepSeekMoE 16B and DeepSeek 7B (Dense).